NOTA METODOLÓGICA · SIMULAÇÃO

A evolução da análise shift-share

De Dunn (1960) a Nazara-Hewings (2004): o que cada modelo recupera de uma economia artificial cujos efeitos verdadeiros são conhecidos

13 variantes 27 UFs × 5 setores × 10 anos Verdadeiro vs. estimado, UF a UF e o mesmo teste na RAIS 2022–2025

O EXPERIMENTO

Uma economia artificial com a resposta certa embutida

$$g[r,i,t] = n[t] + m[i,t] + c[r,i] + \varepsilon[r,i,t]$$

`n[t]`

Efeito nacional

Taxa de crescimento do país em cada ano.

`m[i,t]`

Composição setorial

Desvio de cada setor; média ponderada nula.

`c[r,i]`

Efeito competitivo

Vantagem comum da UF mais interação UF × setor.

`ε[r,i,t]`

Ruído

Choque aleatório que nenhum modelo recupera.

O emprego evolui ano a ano, $E[t+1] = E[t]\cdot(1 + g)$, de modo que ΔE = nacional + composição + competitivo + ruído vale com precisão de máquina. Cada UF tem, portanto, um efeito competitivo **verdadeiro** contra o qual a estimativa de cada modelo é comparada.

COMO LER OS SLIDES DE MODELO

Cada modelo, lado a lado com a verdade

Verdadeiro (DGP) · Estimado pelo modelo · Estimado, não significativo a 5%

Os gráficos mostram, para as 27 UFs ordenadas pelo valor verdadeiro, o par de barras verdadeiro × estimado. Ao lado, três medidas resumem a recuperação na semente 42, e uma linha traz a média de 50 simulações.

Correlação (r)

O modelo acompanha e ordena as UFs como a verdade? 1 é perfeito.

nRMSE

Erro quadrático médio dividido pelo desvio-padrão da verdade. Abaixo de 1 já supera chutar a média; quanto menor, melhor.

Sinal correto

Parcela das 27 UFs em que o modelo acerta se a UF ganha ou perde competitividade.

Cada modelo é avaliado contra o alvo que diz estimar: Esteban-Marquillas e Arcelus I contra o efeito competitivo **homotético** verdadeiro; os demais contra o efeito competitivo verdadeiro.

TRÊS ONDAS E UMA EXTENSÃO ESPACIAL

Cada variante corrige uma falha da anterior

Variante	Problema que ataca	Limite que sobra
Dunn (1960)	linha de base: identidade de 3 termos	competitivo contaminado pela estrutura
Fuchs / Stilwell	viés do ano de ponderação	sensibilidade persiste na alocação
Esteban-Marquillas (1972)	estrutura dentro do competitivo	sinal de AE depende dos pesos
Arcelus (1984) · I	homotetia só no competitivo	DN e EM nulos por construção
Arcelus (1984) · II	competitivo mistura UF e setor	diferencial agregado é −IM por construção
Barff-Knight (1988)	viés ponto a ponto	ainda determinístico
Berzeg (1978, 1984)	nenhum teste estatístico	supõe normalidade
Knudsen (2000)	ANOVA heterocedástica	parâmetros em escala log
Nazara-Hewings (2004)	regiões tratadas como isoladas	sensível à matriz W

Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

LINHA DE BASE · DUNN (1960)

O resíduo competitivo nasce contaminado

$$\Delta E = E_0 \cdot g_n + E_0 \cdot (g_{ni} - g_n) + E_0 \cdot (g_{ri} - g_{ni})$$

Rosenfeld (1959) e Houston (1967) apontaram, e Esteban-Marquillas (1972) formalizou: o terceiro termo é ponderado pelo emprego **observado** da região no setor. Duas regiões com a mesma taxa diferencial recebem efeitos competitivos diferentes só porque uma tem mais emprego ali — o componente que deveria medir vantagem pura mede vantagem × estrutura.

ONDA 1 · HOMOTÉTICA

Mede vantagem e especialização no mesmo número.

ONDA 2 · TEMPORAL

Só as duas pontas do período entram na conta.

ONDA 3 · INFERENCIAL

Identidade determinística não tem erro-padrão.

EXTENSÃO ESPACIAL

Cada região é tratada como ilha, sem vizinhança.

Loveridge e Selting (1998): “SSA é apenas uma identidade contábil praticável: nunca pretendeu ser uma teoria.”

Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

CLÁSSICO · 1960

Dunn: pesos do ano-base

Identidade contábil que reparte ΔE em crescimento nacional, composição setorial e um resíduo competitivo, todos ponderados pelo emprego inicial.

$$\Delta E = E_0 \cdot g_n + E_0 \cdot (g_{ni} - g_n) + E_0 \cdot (g_{ri} - g_{ni})$$

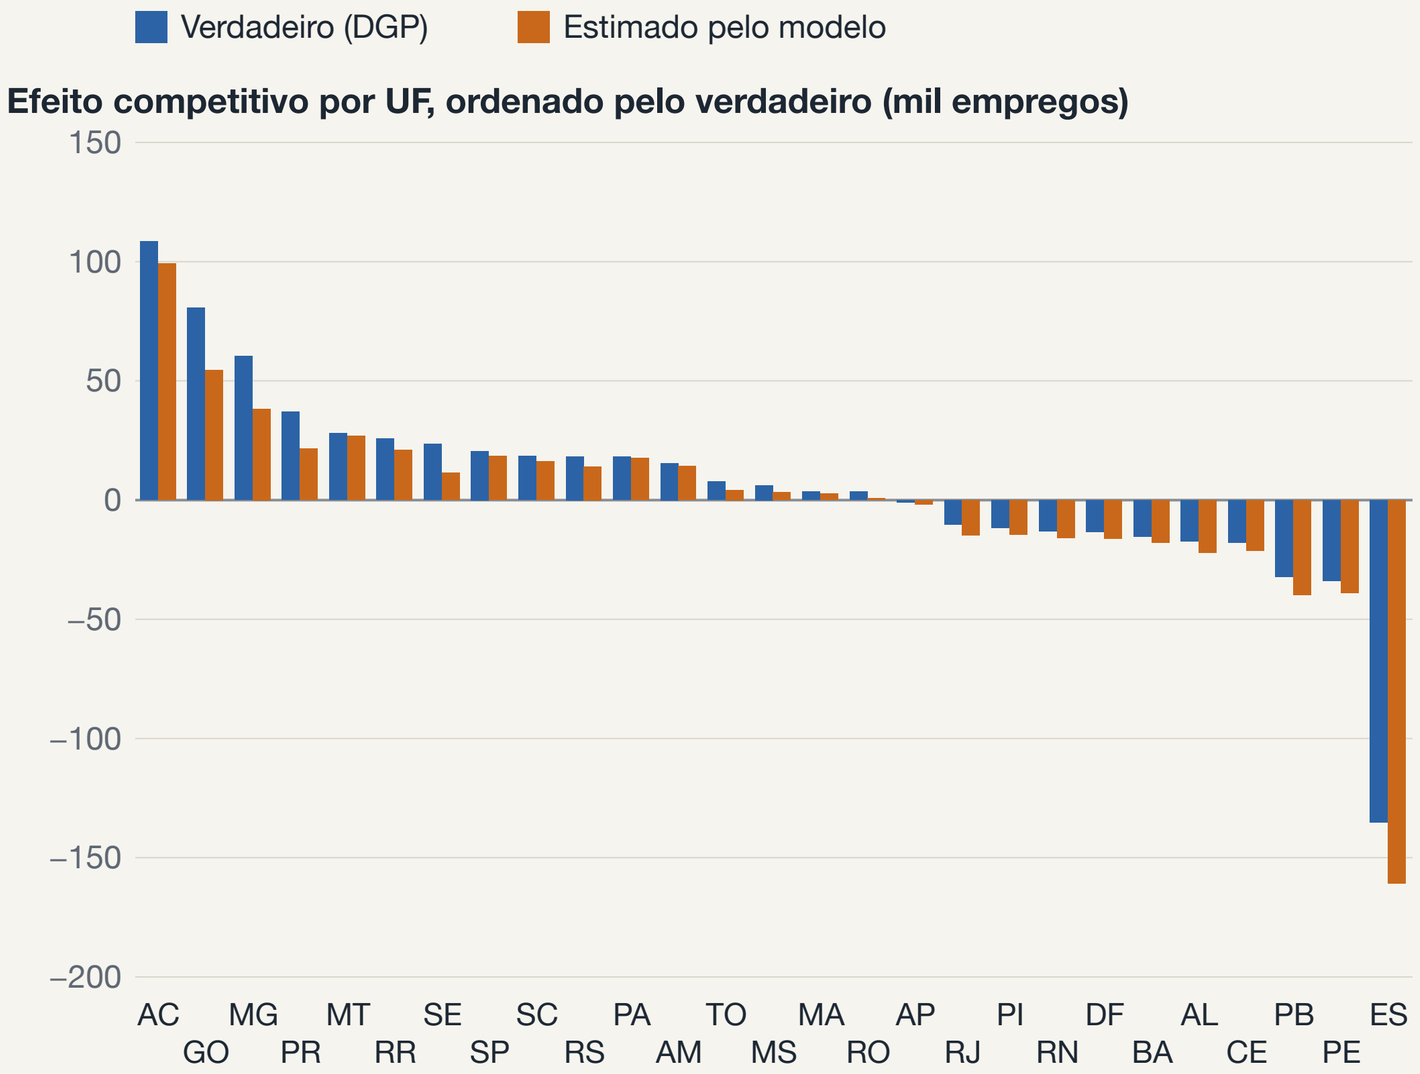
0,985
correlação (r)

0,23
nRMSE

100%
sinal correto

Monte Carlo, 50 sementes · nRMSE médio **0,21** no cenário benigno e **0,29** no de estresse.

Composição setorial: r = 0,992 com a verdade.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 1 DE 3 · 1972–1987

Homotética: tirar a estrutura de dentro do resíduo

A primeira onda aceita a identidade de Dunn e troca o **ponderador**. Em lugar do emprego observado entra o emprego homotético E*, a estrutura que a região teria se reproduzisse exatamente as participações setoriais do país — e a diferença entre os dois pesos passa a ser um componente próprio, o efeito alocação.

PROBLEMA

O efeito competitivo mistura vantagem com especialização: vantagem × estrutura em um único número.

MUDANÇA

Peso contrafactual $E^* = E_{0r} \cdot (E_{0i}/E_{0})$; o competitivo se parte em puro (CE*) e alocação (AE).

LIMITE QUE SOBRA

O sinal de AE depende do ano de ponderação (Herzog-Olsen, 1977) e a homotetia se esgota no competitivo.

Nos próximos quatro slides: Esteban-Marquillas (1972), o efeito alocação, Arcelus I e Arcelus II (1984). Autores da onda: Esteban-Marquillas (1972), Herzog-Olsen (1977), Arcelus (1984), Haynes-Machunda (1987).

ONDA 1 · HOMOTÉTICA · 1972

Esteban-Marquillas

Troca o peso observado pelo emprego homotético E*, a estrutura que a UF teria se reproduzisse as participações setoriais do país. Separa competitividade pura de alocação.

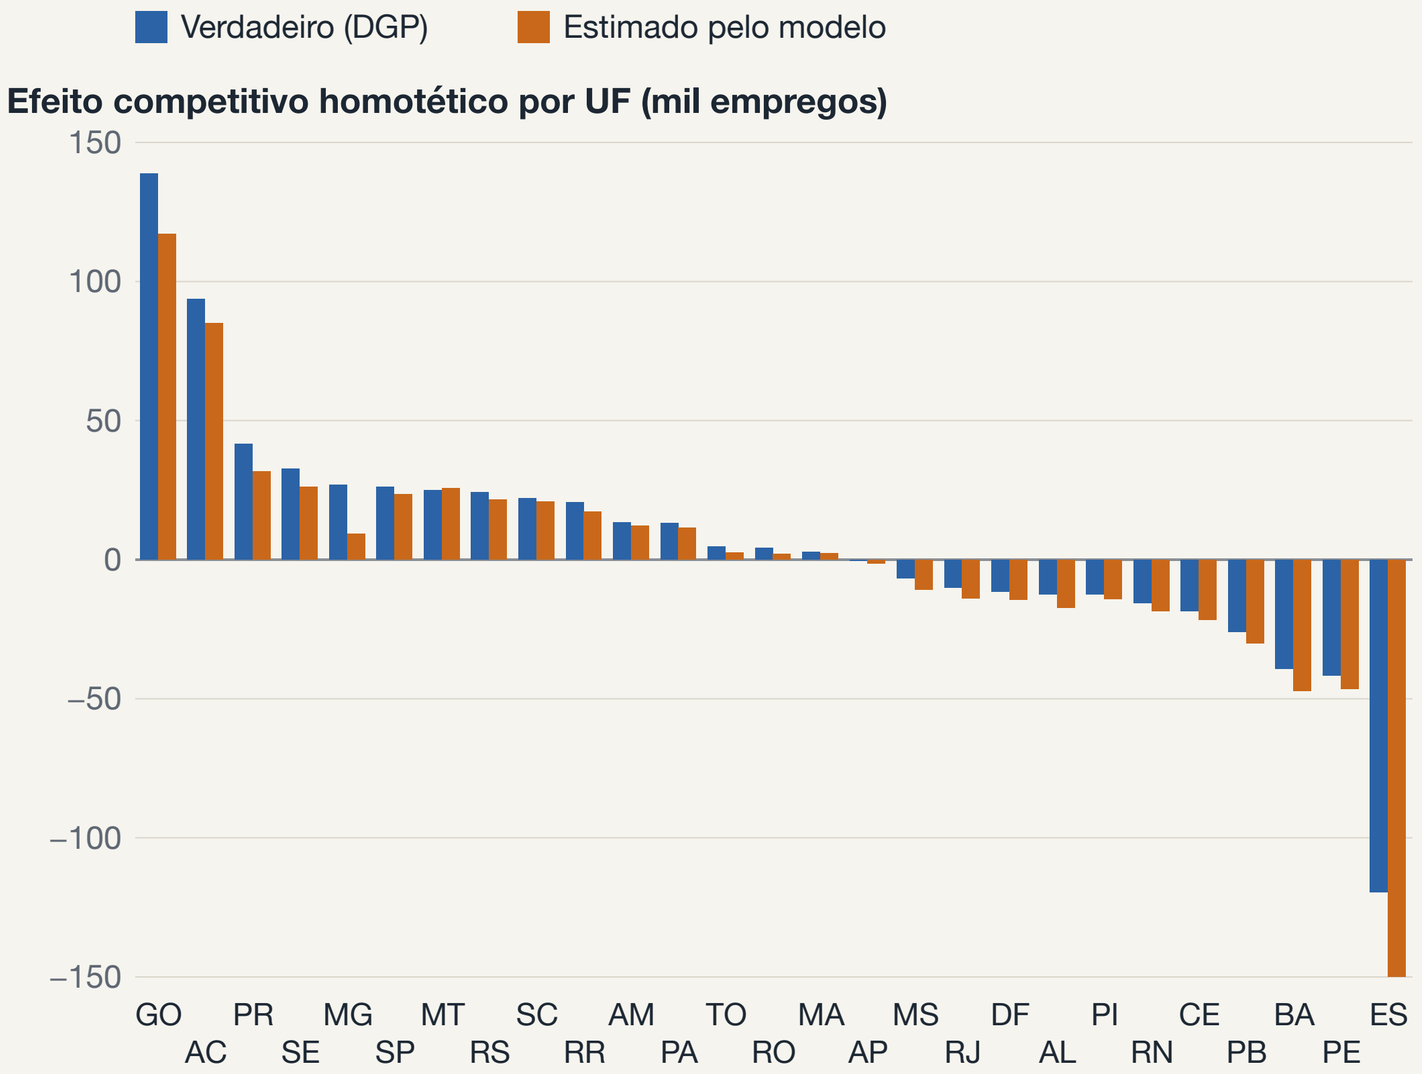
$$E\star = E_{0r} \cdot (E_{0i}/E_{0})$$
$$CE\star = E\star \cdot (g_{ri} - g_{ni})$$

0,988
correlação (r)

0,20
nRMSE

100%
sinal correto

Monte Carlo, 50 sementes · nRMSE médio **0,22** no cenário benigno e **0,30** no de estresse.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 1 · HOMOTÉTICA · 1972

Efeito alocação

Especialização vezes vantagem: positivo quando a UF se concentra nos setores em que é competitiva, negativo quando se concentra onde perde.

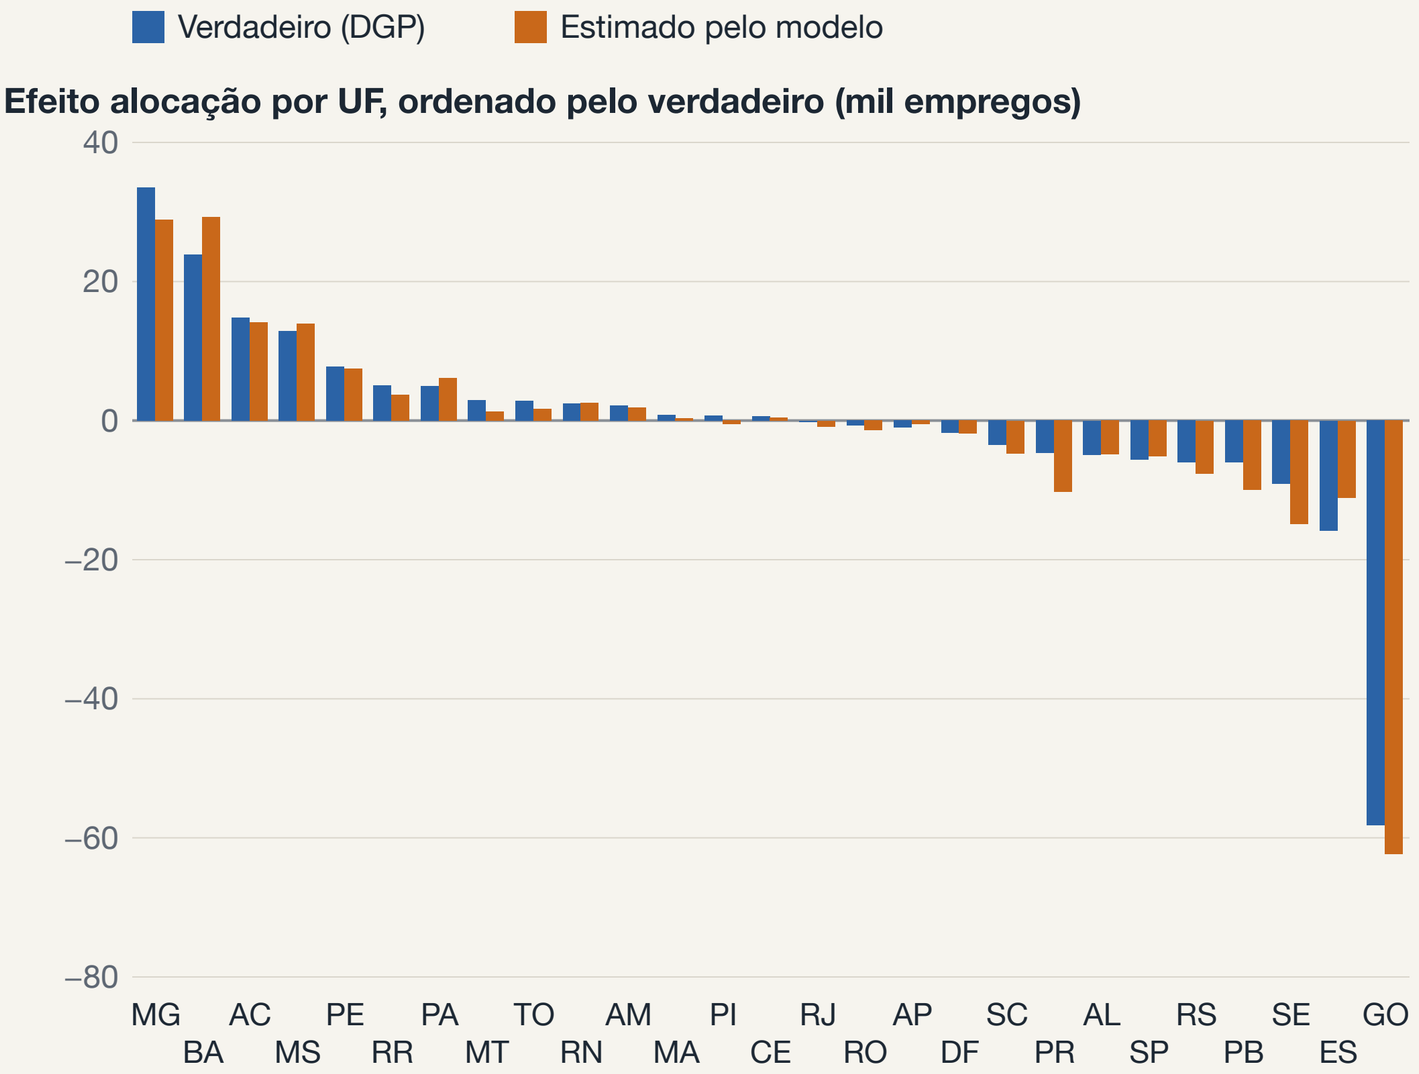
$$AE = (E_0 - E^*) \cdot (g_{ri} - g_{ni})$$

0,988
correlação (r)

0,17
nRMSE

96%
sinal correto

Grupo (média)	Verdadeiro	Estimado
Bem alocadas	11,6	11,5
Neutras	0,2	−0,5
Mal alocadas	−12,0	−13,7



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 1 · HOMOTÉTICA · 1984

Arcelus I: a partição homotética

Estende a partição homotética aos efeitos nacional e de composição. Somados por UF, dois dos quatro novos termos se anulam identicamente.

$$NE = E^{\star} \cdot g_n + (E_0 - E^{\star}) \cdot g_n$$
$$IM = E^{\star} \cdot (g_{ni} - g_n) + (E_0 - E^{\star}) \cdot (g_{ni} - g_n)$$

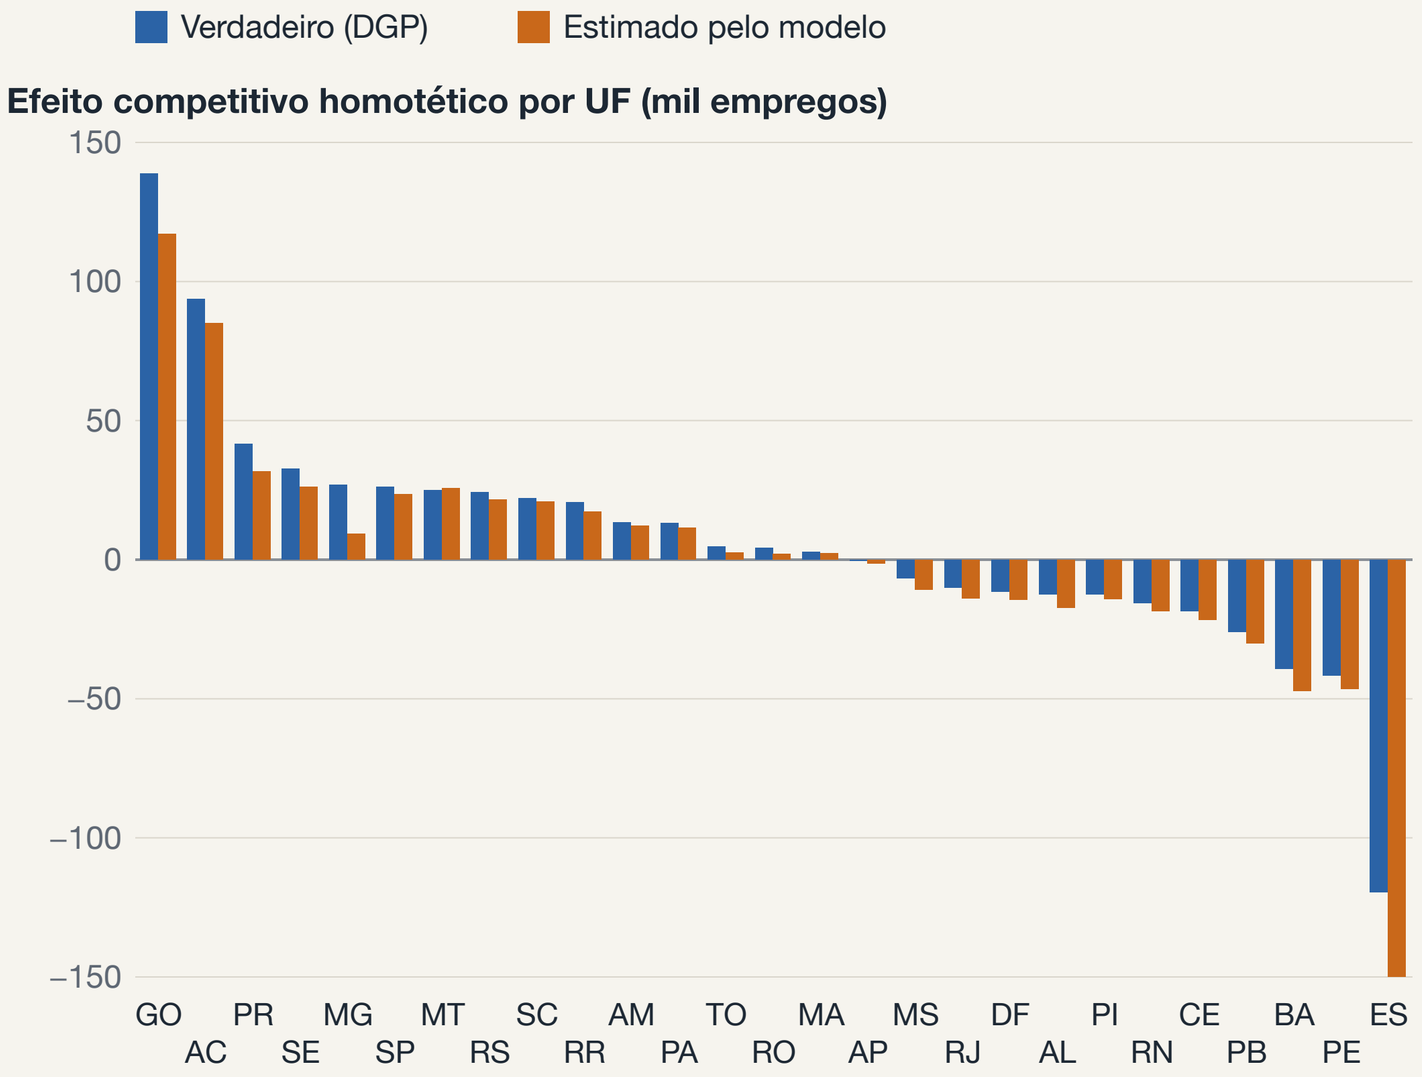
0,988
correlação (r)

0,20
nRMSE

100%
sinal correto

Monte Carlo, 50 sementes · nRMSE médio **0,22** no cenário benigno e **0,30** no de estresse.

Na simulação, |DN| e |EM| ficam abaixo de 10^{-9} em todas as UFs: o competitivo é o de Esteban-Marquillas.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 1 · DESLOCAMENTO REGIONAL · 1984

Arcelus II: a partição do competitivo

Troca a referência, não o ponderador: separa o quanto a UF inteira cresce acima do país do quanto um setor se destaca dentro dela.

$$r = E_0 \cdot (g_UF - g_n)$$
$$d = E_0 \cdot [(g_r_i - g_UF) - (g_{ni} - g_n)]$$

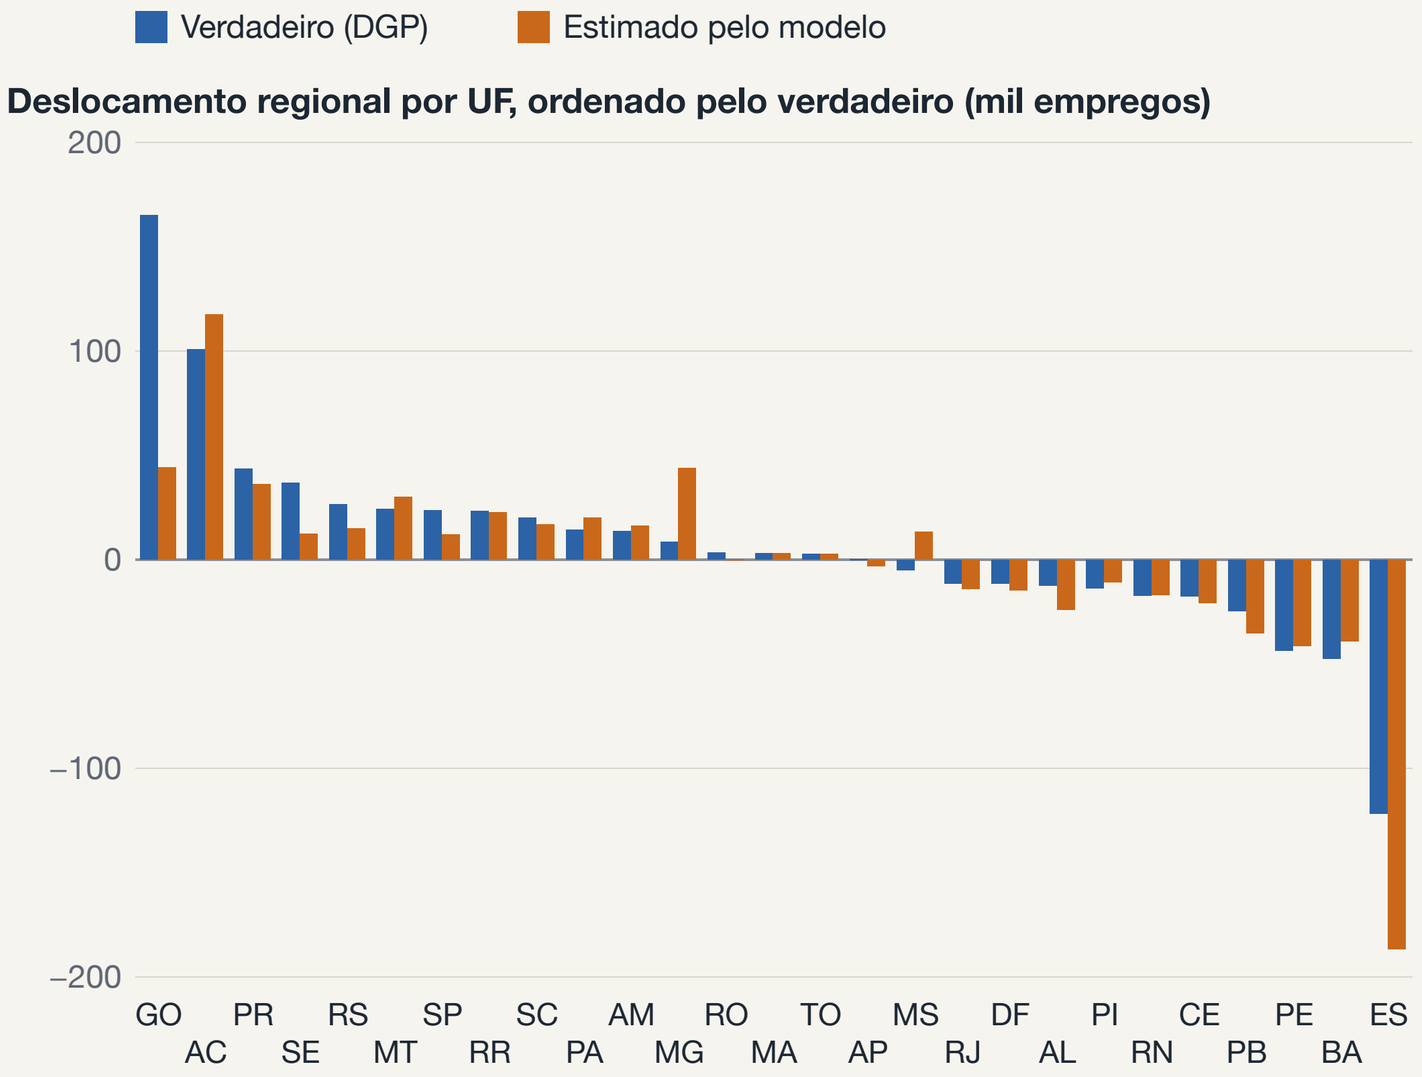
0,836 correlação (r)

0,59 nRMSE

93% sinal correto

O competitivo total é **idêntico** ao de Dunn com pesos-base: $r + d = E_0 \cdot (g_r_i - g_{ni})$ célula a célula. O modelo acrescenta a partição, não o total.

Somado por UF, o diferencial é −IM por construção: r = −0,199, nRMSE = 1,16, sinal correto em 44%. Pior que chutar a média.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 2 DE 3 · 1959–1988

Temporal: a trajetória entre as duas pontas

A segunda onda não discute o ponderador, mas **quando** ele é medido. Fuchs (1959) mostrou que o efeito de composição é sensível ao ano de ponderação; Stilwell (1969) propôs o extremo terminal e Ashby (1970) o criticou. Barff e Knight (1988), retomando Thirlwall (1967), foram além: partiram o intervalo em subperíodos e somaram as decomposições.

PROBLEMA

A comparação ponto a ponto ignora a trajetória e a escolha do ano de ponderação não é neutra.

MUDANÇA

Pesos terminais, média cinquenta-cinquenta ou soma de K decomposições subperiódicas.

LIMITE QUE SOBRA

Continua determinística e exige dados de alta frequência para montar os subperíodos.

Nos próximos quatro slides: Dunn com pesos terminais, Dunn com a média de Fuchs, Barff-Knight (1988) e Esteban-Marquillas dinâmico, que soma as duas primeiras ondas. Autores da onda: Fuchs (1959), Stilwell (1969), Ashby (1970), Barff-Knight (1988).

ONDA 2 · PESOS TERMINAIS · 1969

Dunn: pesos do ano terminal

A mesma identidade, reponderada pelo emprego final com a taxa reversa. Stilwell (1969) propôs essa “composição reversa”; Ashby (1970) a criticou como excessiva.

$$g' = (E_0 - E_1)/E_1$$
$$CE = -E_1 \cdot (g'_{ri} - g'_{ni})$$

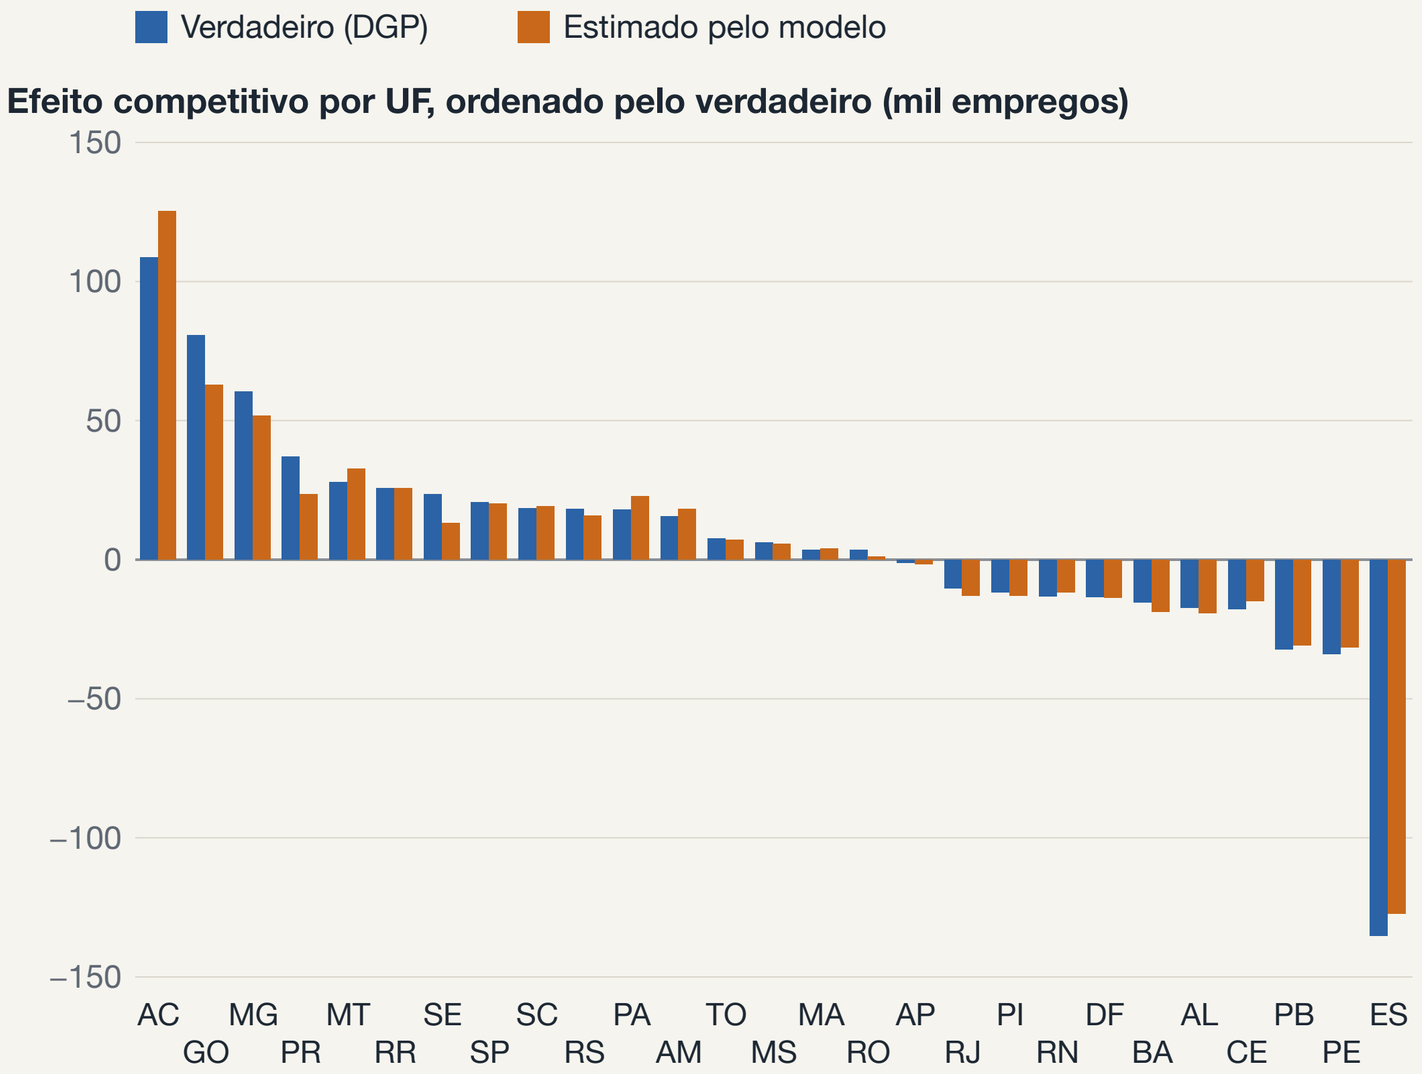
0,988
correlação (r)

0,15
nRMSE

100%
sinal correto

Monte Carlo, 50 sementes · nRMSE médio **0,37** no cenário benigno e **0,51** no de estresse.

É a pior variante em magnitude na média de 50 simulações; a composição setorial cai para r = 0,842.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 2 · MÉDIA DOS PESOS · 1959

Dunn: média dos pesos (Fuchs)

Fuchs (1959) mostrou que o efeito de composição é sensível ao ano de ponderação e propôs a média entre pesos-base e pesos-terminais.

```
CE = ½·(CE_base + CE_terminal)
```

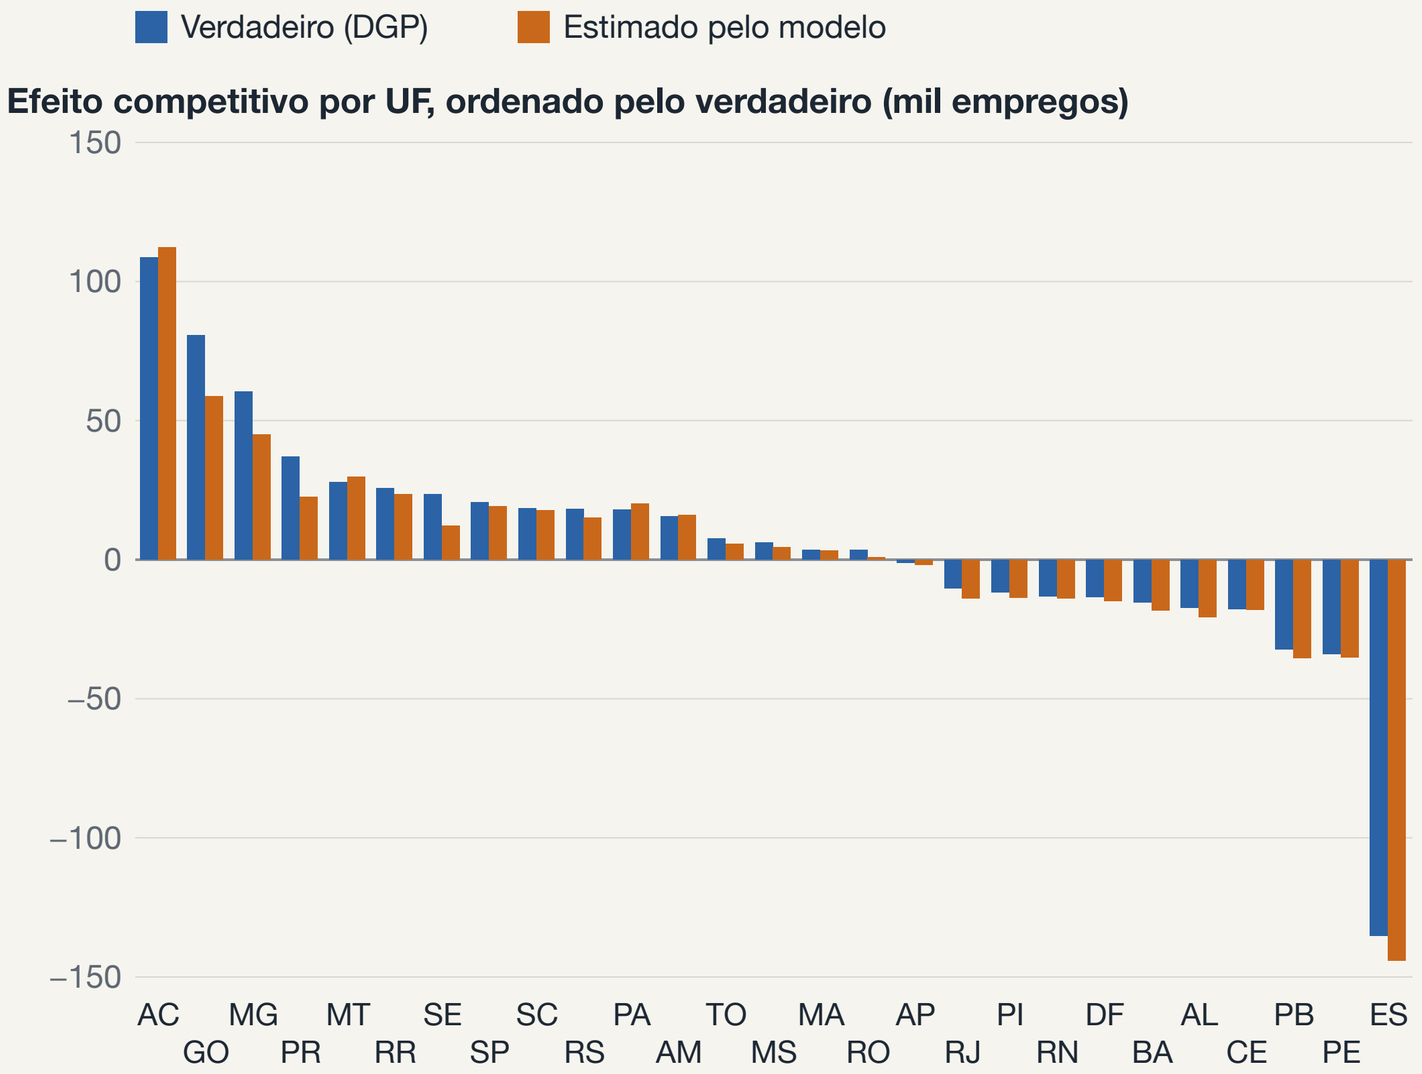
0,991
correlação (r)

0,16
nRMSE

100%
sinal correto

Monte Carlo, 50 sementes · nRMSE médio **0,26** no cenário benigno e **0,37** no de estresse.

Fica entre as duas convenções: melhor que a terminal, pior que a base na média.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 2 · DINÂMICA · 1988

Barff-Knight dinâmico

Recalcula a identidade clássica ano a ano, com o emprego do início de cada ano como peso, e soma. Elimina o viés de comparar só as pontas.

$$CE = \Sigma_t \; E_{t-1} \cdot (g_{ri}^{(t)} - g_{ni}^{(t)})$$

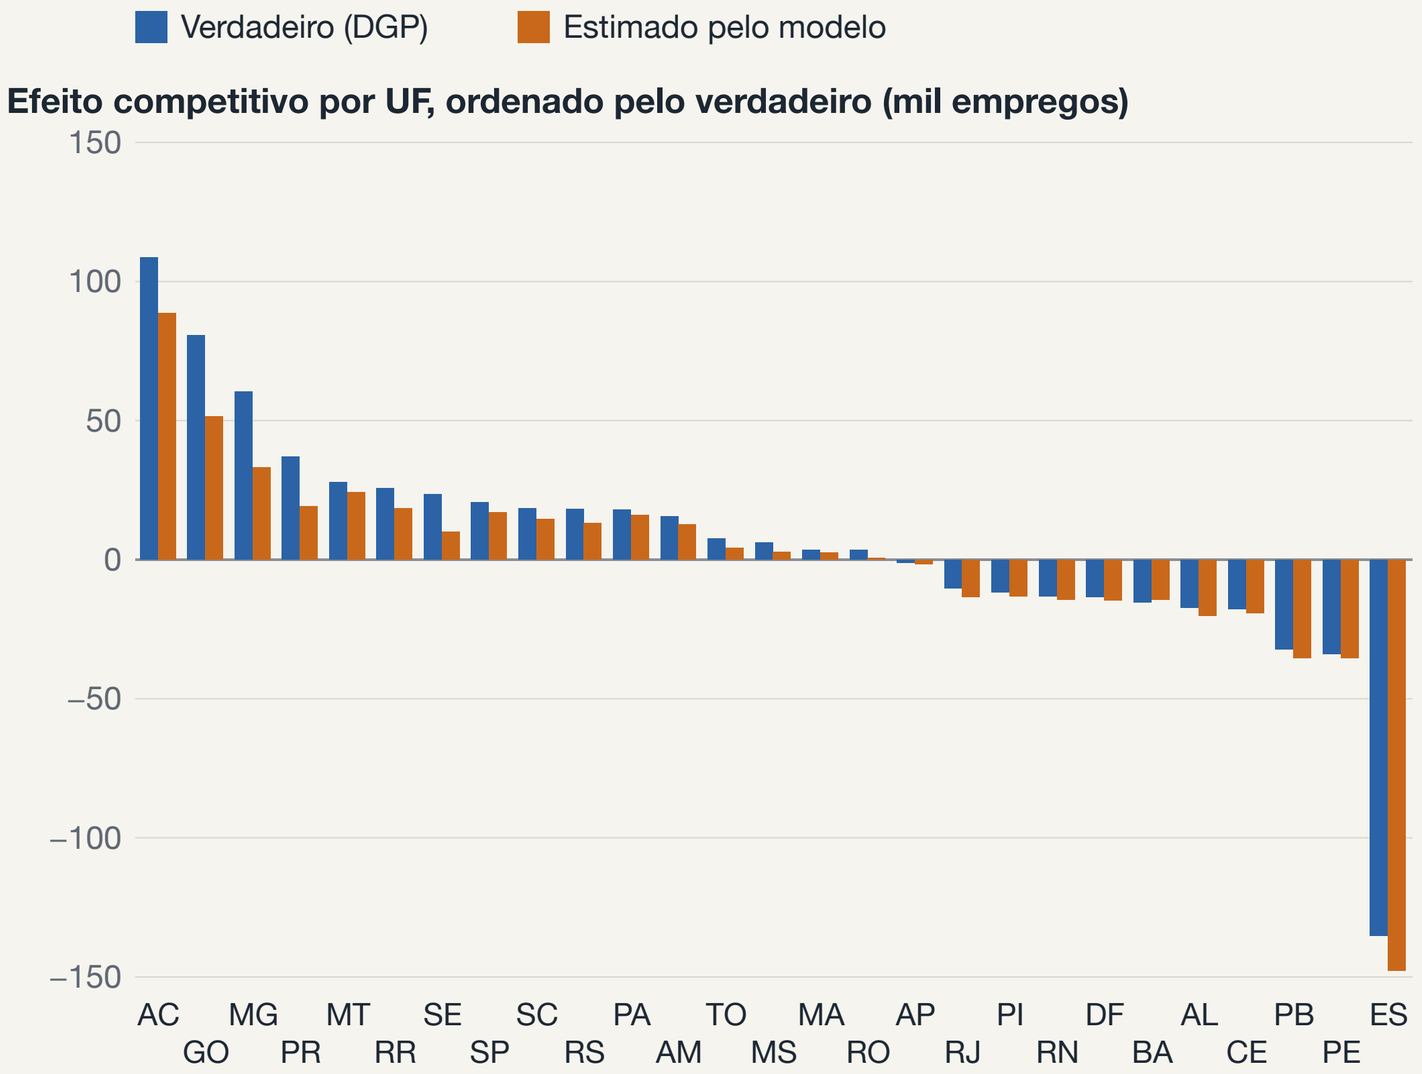
0,984
correlação (r)

0,24
nRMSE

100%
sinal correto

Monte Carlo, 50 sementes · nRMSE médio **0,19** no cenário benigno e **0,25** no de estresse.

No estresse, reduz o erro dos pesos-base de 0,29 para 0,25.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDAS 1 + 2

Esteban-Marquillas dinâmico

Junta as duas correções: o emprego homotético é recalculado a cada ano e o efeito competitivo puro é somado ao longo da trajetória.

$$CE^{*} = \sum_{t} E^{*}_{t} \cdot (g_{ri}^{(t)} - g_{ni}^{(t)})$$

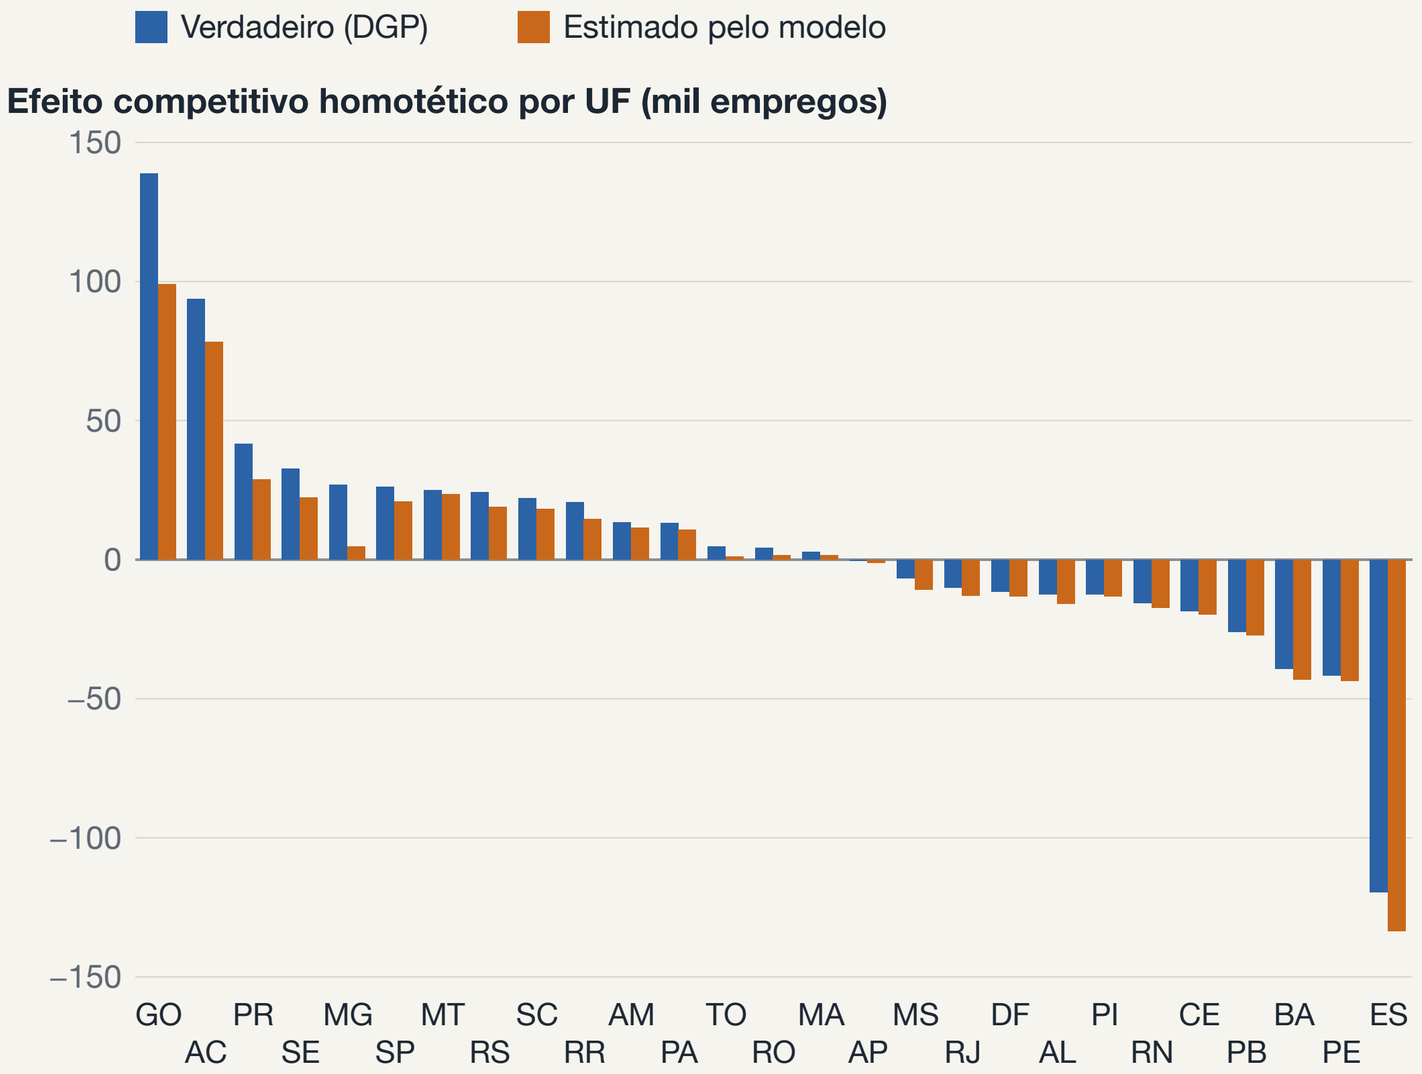
0,985
correlação (r)

0,24
nRMSE

100%
sinal correto

Monte Carlo, 50 sementes · nRMSE médio **0,18** no cenário benigno e **0,24** no de estresse.

Alocação: r = 0,984 com a verdade.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 3 DE 3 · 1976–2000

Inferencial: um número sem erro-padrão não é resultado

A terceira onda ataca o que as duas primeiras não podiam tocar. Como observam Selting e Loveridge (1992), uma identidade determinística não tem erro-padrão: não há como dizer se um efeito competitivo é vantagem ou ruído amostral. Berzeg (1978, 1984) recasta a identidade como ANOVA, em que o competitivo é o **resíduo** de uma regressão; Knudsen (2000) a deriva da teoria da informação.

PROBLEMA

Nenhum componente da SSA clássica admite teste de hipótese, porque nenhum tem distribuição.

MUDANÇA

Regressão das taxas em dummies (ANOVA) e mínima informação discriminante (GLM de Poisson log-linear).

LIMITE QUE SOBRA

Supõe normalidade; parâmetros em escala log; exige correção de dispersão (quase-Poisson).

Nos próximos quatro slides: Berzeg ANOVA, regressão full-analogue, Knudsen estático e Knudsen dinâmico. Autores da onda: Buck-Atkins (1976), Berzeg (1978, 1984), Patterson (1991), Knudsen (2000).

ONDA 3 · INFERENCIAL · 1978

Berzeg: ANOVA

Reescreve a identidade como regressão das taxas em dummies de setor. O efeito competitivo vira o resíduo médio da UF, com erro-padrão e teste t.

$$g_{rit} = \Sigma\ \beta_i D_i + u_{rit}\ \text{(MQP)}$$
$$t = \bar{u}_r\ /\ ep(\bar{u}_r)$$

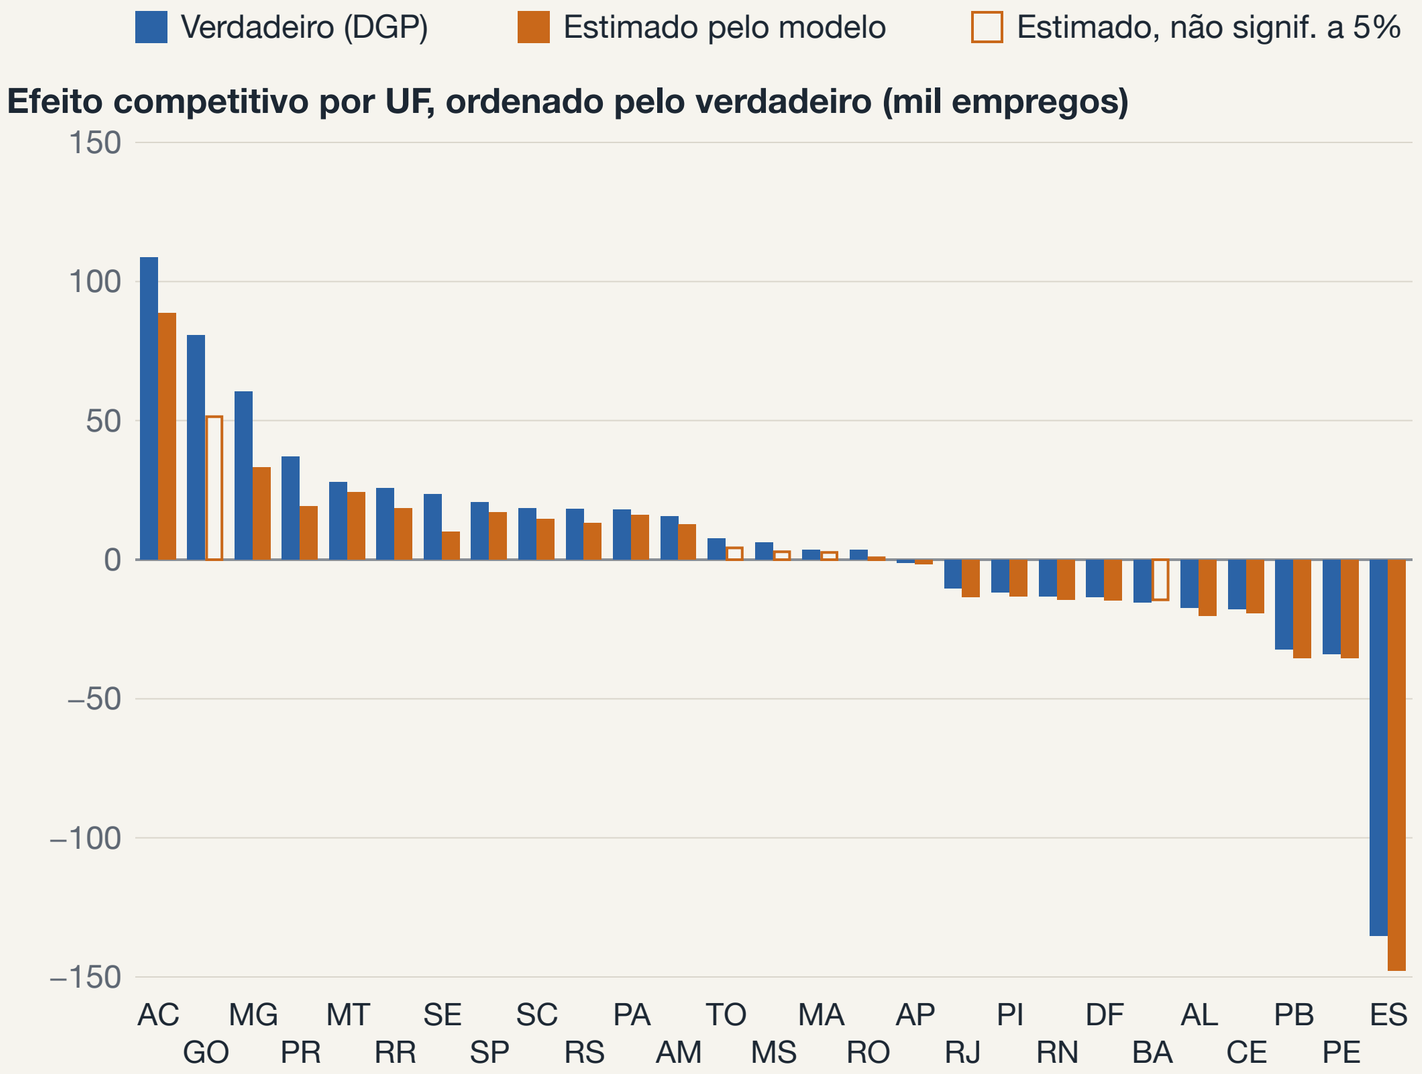
0,984
correlação (r)

0,24
nRMSE

100%
sinal correto

Teste a 5%: **21 de 27** UFs significativas; detecta 100% das UFs de vantagem forte e marca 44% das de vantagem fraca.

Estimativas pontuais idênticas às de Barff-Knight: a ANOVA só acrescenta os erros-padrão.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 3 · INFERENCIAL

Regressão full-analogue

Buck-Atkins (1976) e Patterson (1991): taxas anuais em efeitos de ano, setor × ano e região, com restrições de soma zero ponderadas.

$$g_{r\,i\,t} = Y_t + I_{i\,t} + R_r + e \quad \text{(MQP)}$$

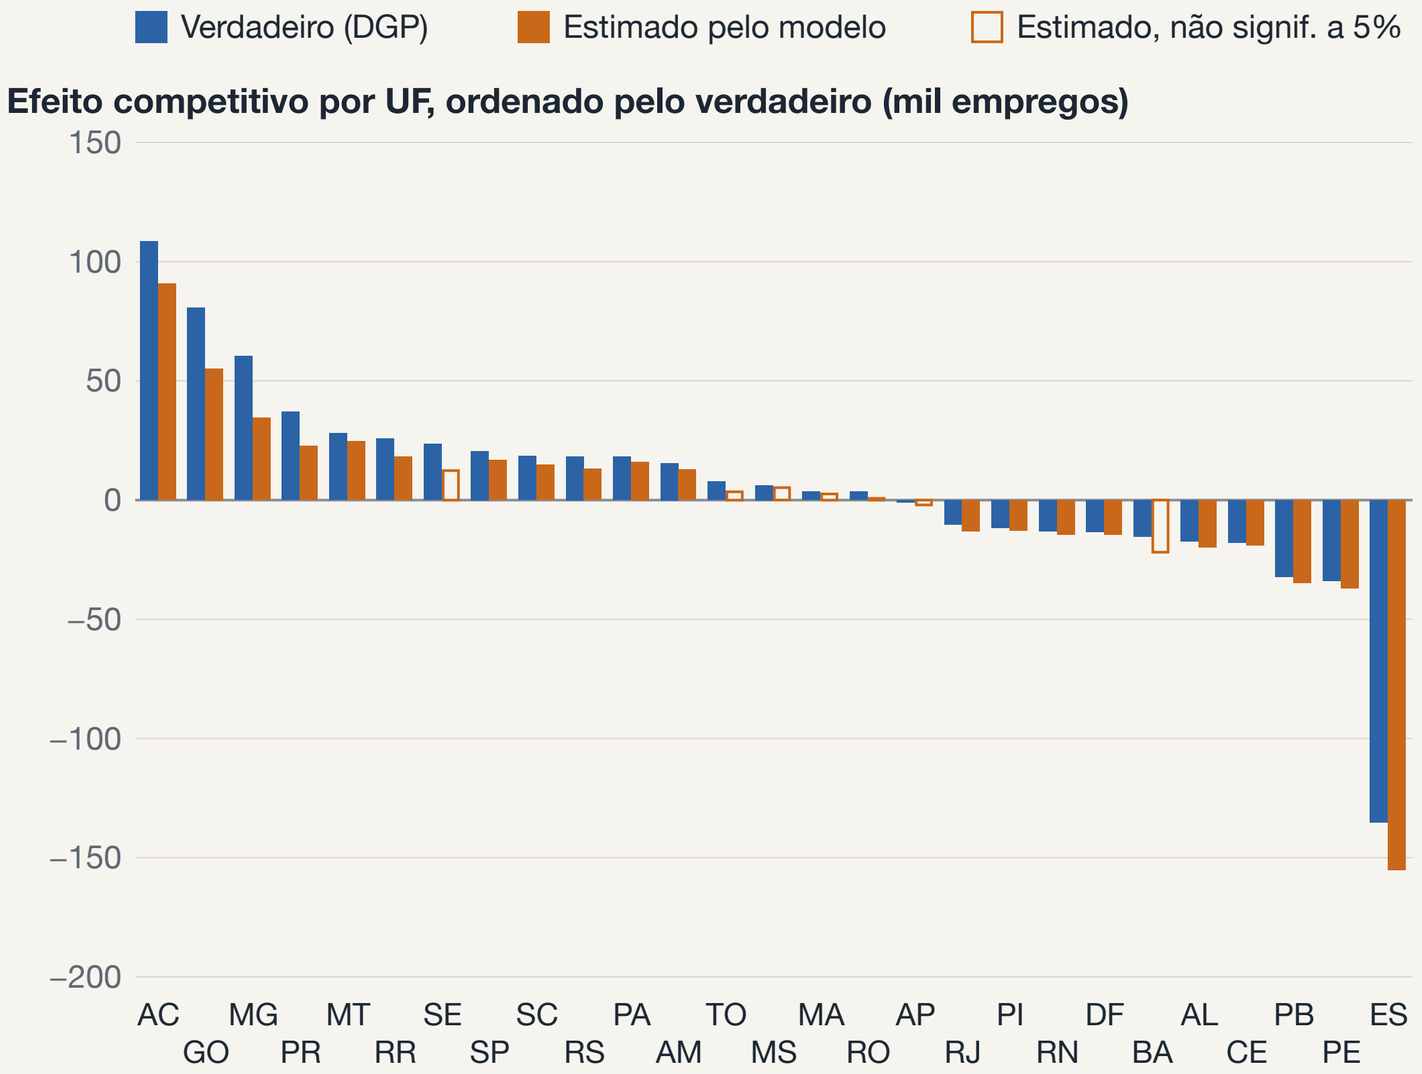
0,985
correlação (r)

0,23
nRMSE

100%
sinal correto

Teste a 5%: **20 de 27** UFs significativas; detecta 100% das UFs de vantagem forte e marca 33% das de vantagem fraca.

Monte Carlo, 50 sementes · nRMSE médio **0,18** no cenário benigno e **0,25** no de estresse.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 3 · TEORIA DA INFORMAÇÃO · 2000

Knudsen: forma estática

Mínima informação discriminante com restrição de margens setoriais e regionais — a extensão de Arcelus II: modelo log-linear estimado como GLM de Poisson com offset ln E_0, uma única transição de dez anos.

$$\ln(E_1/E_0) = A + O_i + D_r$$
$$CE = (e^{\tilde{D}_r} - 1)\cdot W_r$$

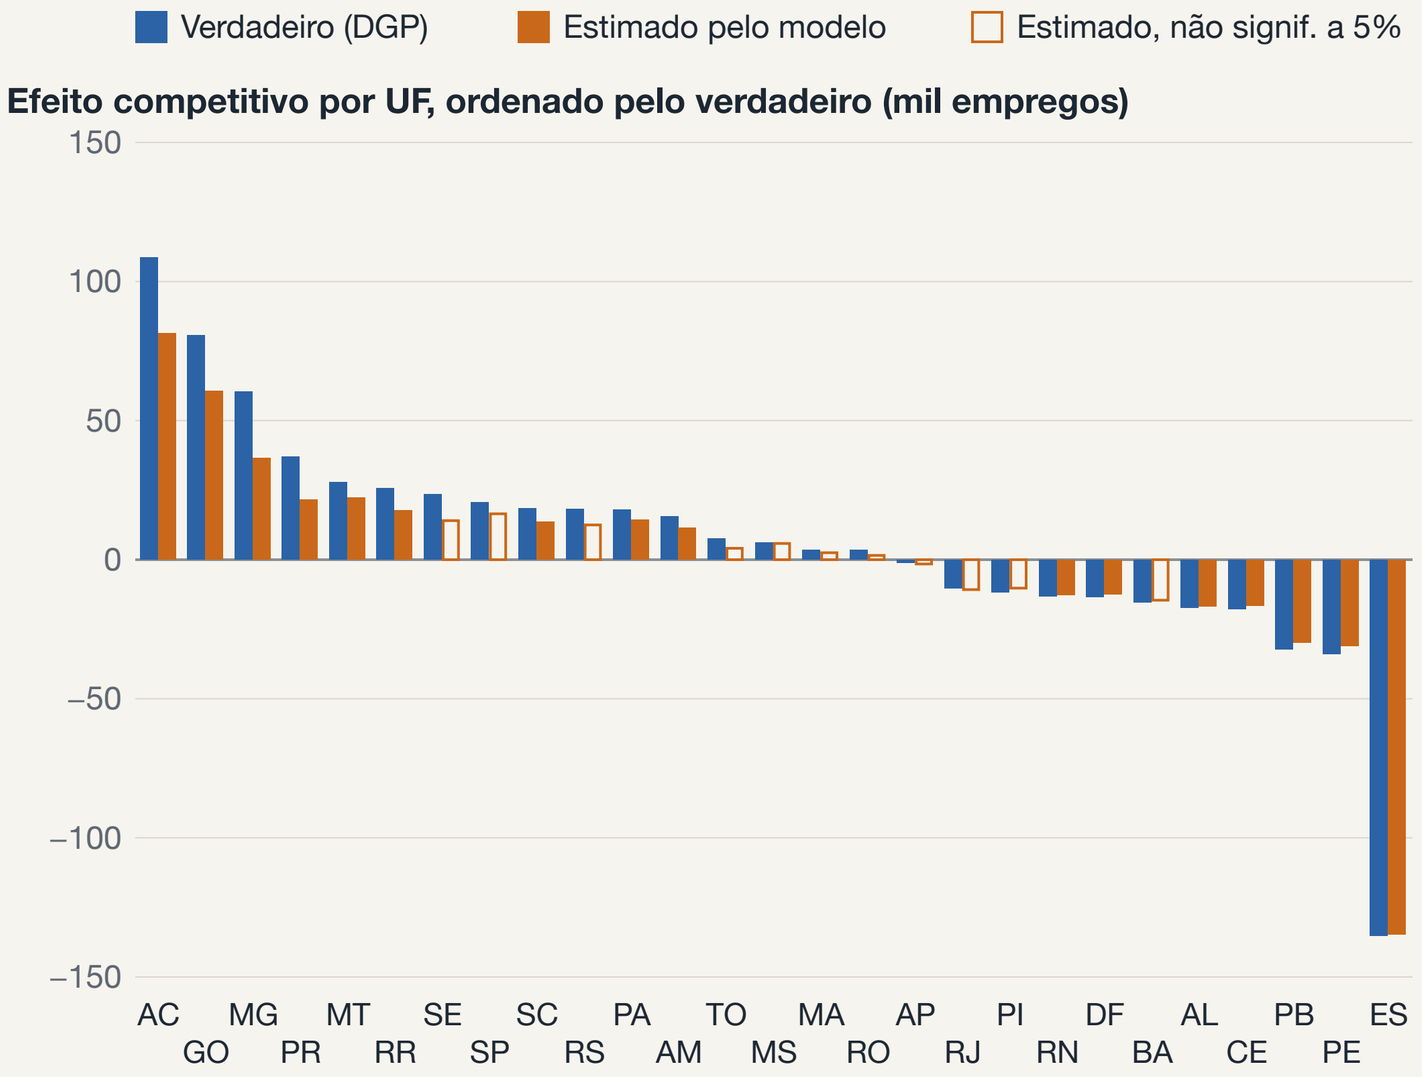
0,991
correlação (r)

0,22
nRMSE

100%
sinal correto

Teste a 5%: **16 de 27** UFs significativas; detecta 89% das UFs de vantagem forte e marca 22% das de vantagem fraca.

Monte Carlo, 50 sementes · nRMSE médio **0,24** no cenário benigno e **0,30** no de estresse.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

ONDA 3 · TEORIA DA INFORMAÇÃO · 2000

Knudsen: forma dinâmica

Acrescenta à tabela a dimensão do tempo, com um efeito T_t para cada par de anos adjacentes.

$$\ln(E_t/E_{t-1}) = A + O_i + D_r + T_t$$

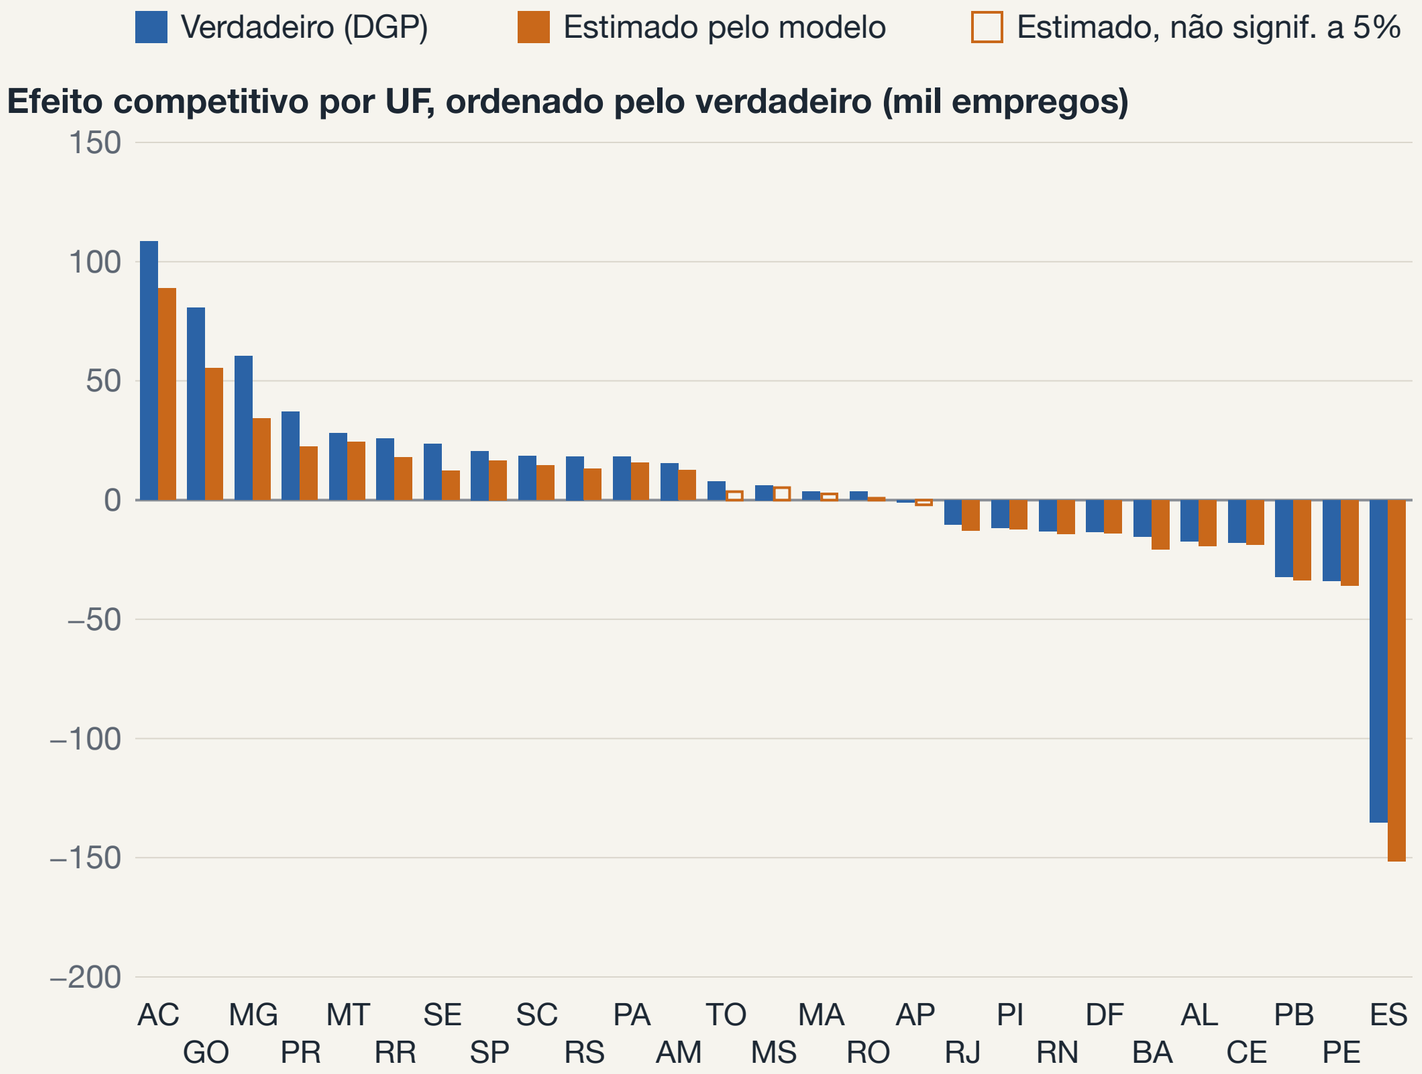
0,986
correlação (r)

0,23
nRMSE

100%
sinal correto

Teste a 5%: **22 de 27** UFs significativas; detecta 100% das UFs de vantagem forte e marca 44% das de vantagem fraca.

Monte Carlo, 50 sementes · nRMSE médio **0,19** no cenário benigno e **0,25** no de estresse.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

EXTENSÃO ESPACIAL · 2004

Vizinhos que não eram para existir

Nazara e Hewings (2004) atacam um pressuposto comum às três ondas: o de que regiões vizinhas não interagem. Com uma matriz de pesos espaciais W, o país deixa de ser a única referência — a vizinhança entra entre a região e a média nacional, e o competitivo se parte em quanto a vizinhança supera o país e quanto a região supera a vizinhança.

PROBLEMA

Cada região é tratada como isolada, embora partilhe mercados de trabalho e transbordamentos com as vizinhas.

MUDANÇA

Matriz W de contiguidade; defasagem espacial $(Wc)_r$ e taxonomia de vinte estruturas de decomposição.

LIMITE QUE SOBRA

Sensível à especificação de W e exige N grande: com 5 regiões o I de Moran não tem poder algum.

Nos próximos dois slides: Nazara-Hewings estático e dinâmico. O I de Moran é calculado sobre a taxa competitiva $c_r = CE_r/E_{0r}$, nunca sobre o emprego em nível — em nível, o tamanho das UFs encobre inteiramente o padrão espacial.

EXTENSÃO ESPACIAL · 2004

Nazara-Hewings estático

Troca o país pela vizinhança como referência: o efeito competitivo se divide em quanto a vizinhança supera o país e quanto a UF supera a vizinhança.

$$\tilde{g}_{ri} = \Sigma_k \, w_{rk} \cdot g_{ki}$$

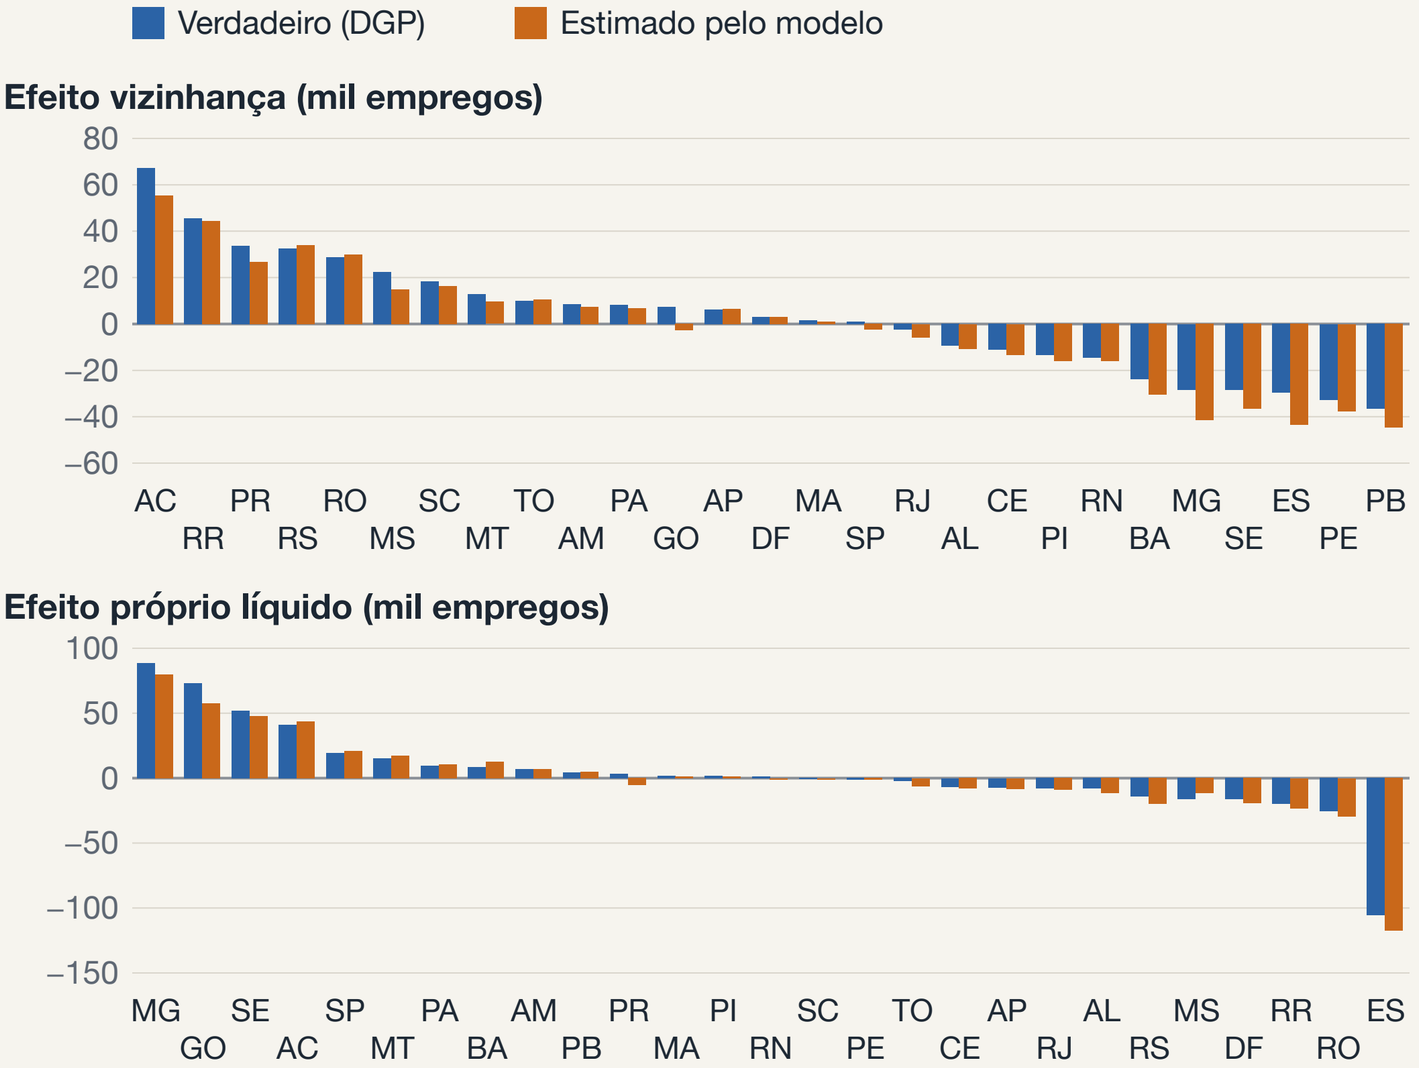
$$CE = E_0 \cdot (\tilde{g}_{ri} - g_{ni}) + E_0 \cdot (g_{ri} - \tilde{g}_{ri})$$

0,987
r vizinhança

0,991
r próprio

0,15
nRMSE próprio

Monte Carlo benigno · nRMSE vizinhança **0,36**, próprio **0,20**.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

EXTENSÃO ESPACIAL · 2004

Nazara-Hewings dinâmico

Troca o país pela vizinhança como referência: o efeito competitivo se divide em quanto a vizinhança supera o país e quanto a UF supera a vizinhança.

$$\tilde{g}_{ri} = \Sigma_k \, w_{rk} \cdot g_{ki}$$

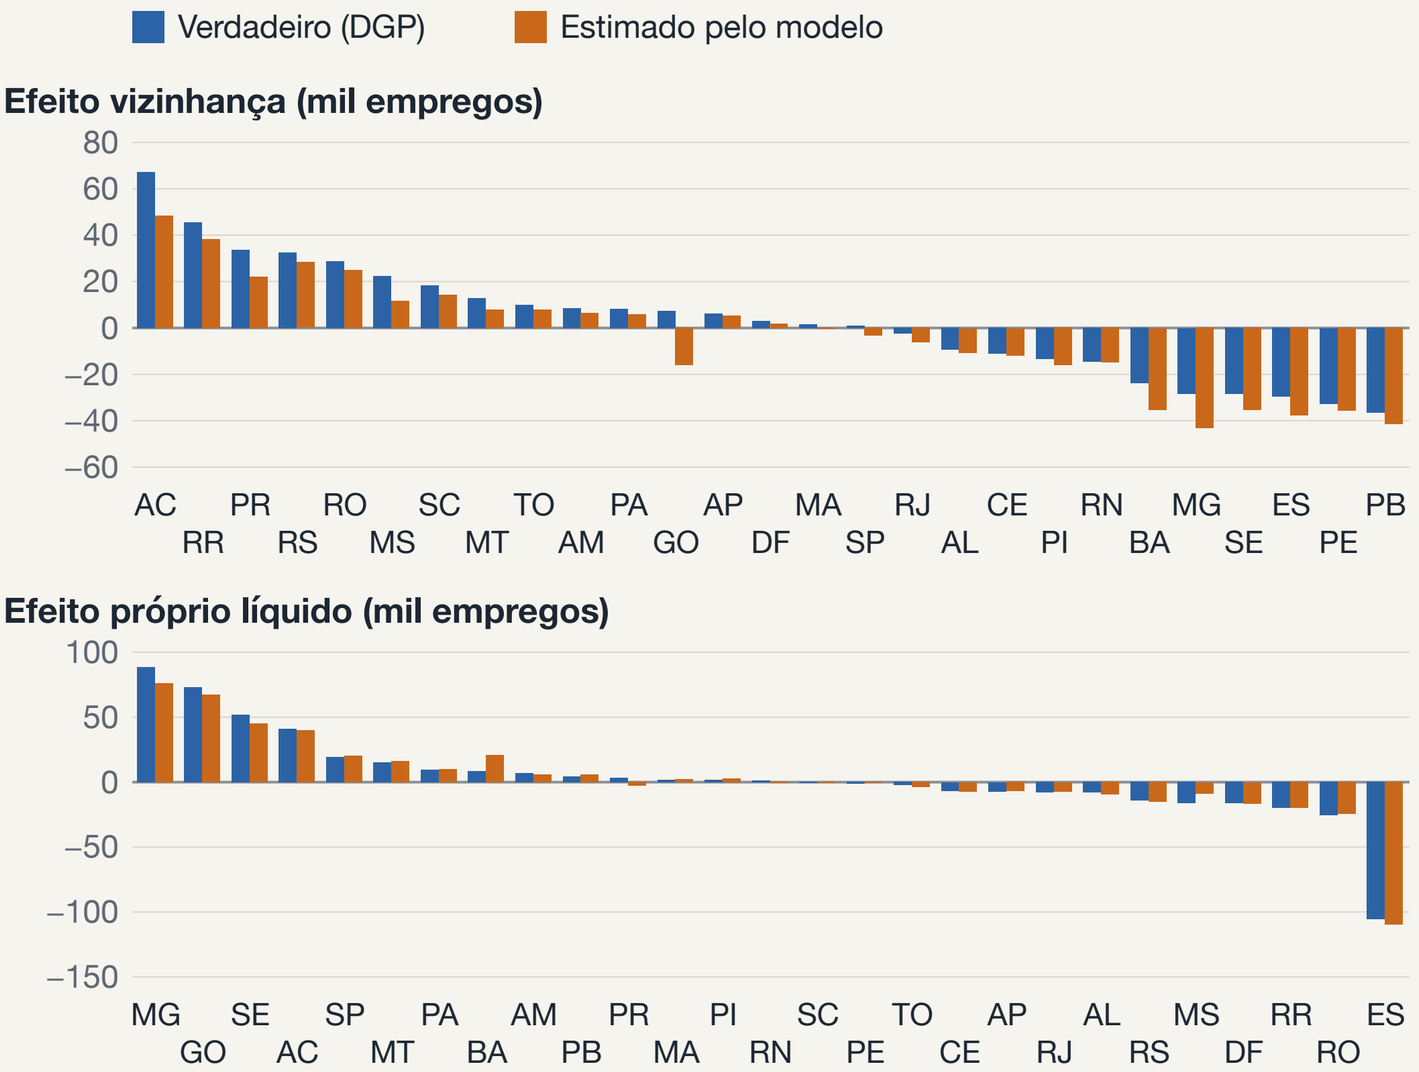
$$CE = E_0 \cdot (\tilde{g}_{ri} - g_{ni}) + E_0 \cdot (g_{ri} - \tilde{g}_{ri})$$

0,973
r vizinhança

0,992
r próprio

0,13
nRMSE próprio

Monte Carlo benigno · nRMSE vizinhança **0,29**, próprio **0,09**.



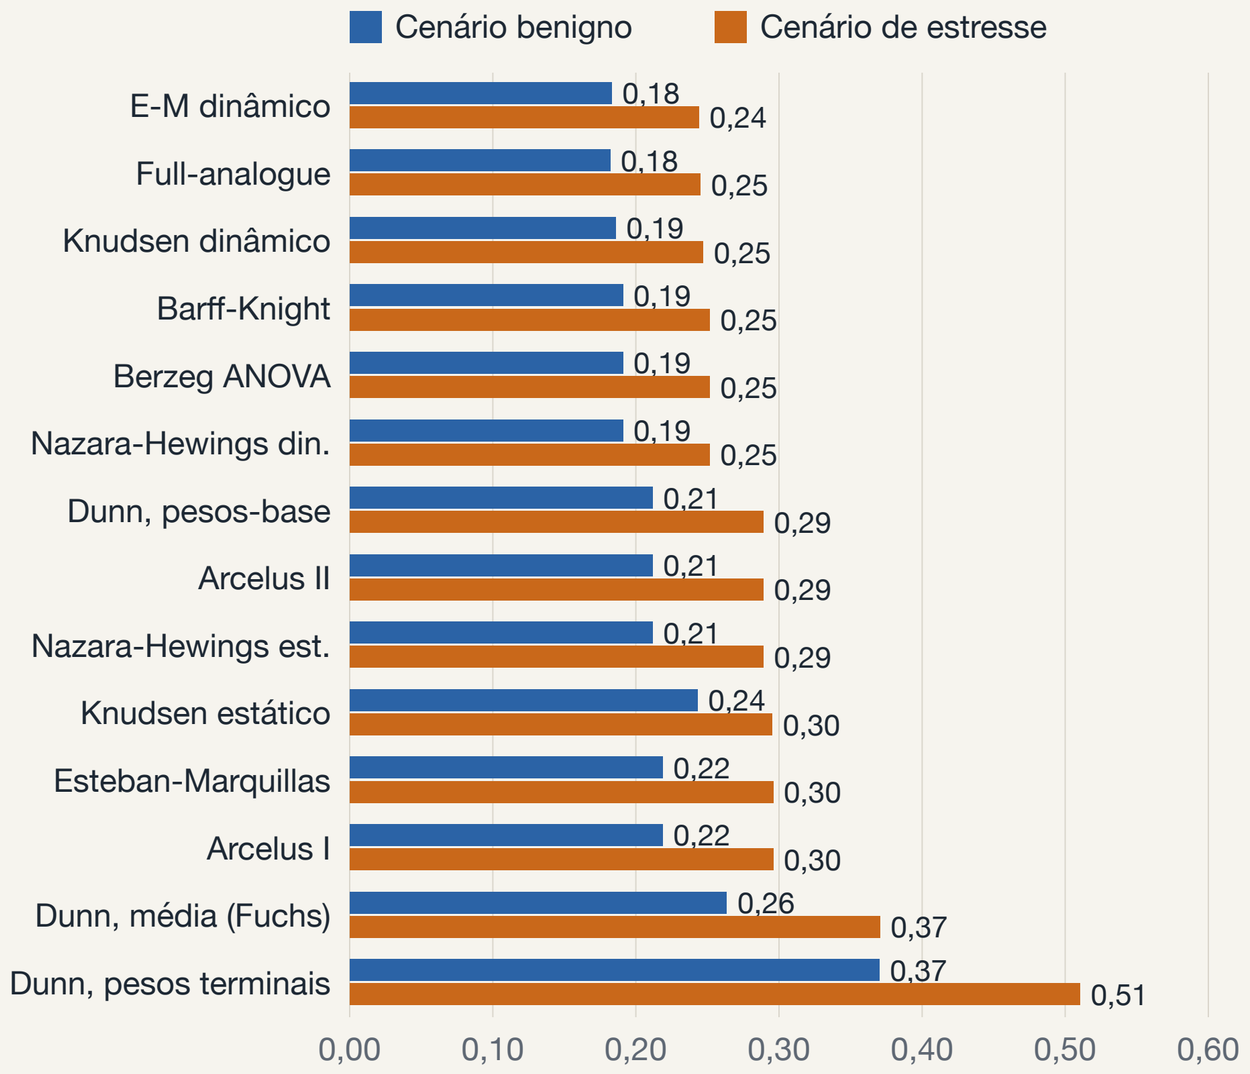
Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

SÍNTESE · 50 SIMULAÇÕES

Todos ordenam bem; a magnitude separa

Correlação com a verdade entre 0,95 e 0,99 em todos os modelos. O erro de magnitude (nRMSE, menor é melhor) favorece as formas dinâmicas, e a distância cresce no cenário volátil.

Pesos terminais quase dobram o erro das formas dinâmicas sob estresse.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

SÍNTESE · CINCO CASOS

Cinco UFs, verdade e estimativa lado a lado

Efeito competitivo em mil empregos, semente 42. A *faixa* é o mínimo e o máximo entre as 11 variantes de alvo clássico; Esteban-Marquillas, Arcelus I e E-M dinâmico estimam outro alvo, o homotético.

UF	Verdadeiro	Dunn-base	Terminal	Barff-Knight	Knudsen est.	Faixa das 11	O que o caso revela
AC	108,6	99,2	125,3	88,6	81,5	81,5 a 125,3	**Primeira colocada nas 11** variantes — mas a faixa abre 43,8 mil empregos, 40% do valor verdadeiro.
ES	−135,2	−160,9	−127,2	−147,6	−134,6	−160,9 a −127,2	Mal alocada, **sinal correto nas 11**. Knudsen erra 0,6 mil; Dunn com pesos-base, 25,7 mil.
GO	80,7	54,6	62,8	51,4	60,7	51,4 a 62,8	Alocação de −58,2 mil: **todas as 11** subestimam a vantagem, de 18,0 a 29,3 mil.
MG	60,4	38,3	51,7	33,2	36,5	33,2 a 51,7	Taxa de 0,12% contra 2,04% do AC, e efeitos da mesma ordem em nível: é **escala**, não desempenho.
AP	−1,1	−1,8	−1,6	−1,6	−1,5	−2,0 a −1,5	Vantagem nula (0,06%): **3 dos 4** modelos inferenciais recusam significância a 5%.

Ordenação e sinal são consensuais; a magnitude não. Onde a UF é mal alocada (GO, ES) ou grande com taxa pequena (MG), o resíduo absorve o que não deveria — e nenhuma variante de alvo clássico corrige isso.

Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

SÍNTESE · BALANÇO

Pontos fortes e pontos fracos da abordagem

O que a abordagem entrega

Ordenação sobrevive a tudo — Na semente 42, correlação com a verdade entre 0,98 e 0,99 nas 11 variantes, e sinal correto em todas elas nos cinco casos do slide anterior.

A identidade fecha — A soma dos componentes reproduz ΔE à precisão de máquina. Nada do resultado depende de convergência, ajuste ou escolha de estimador.

A alocação faz o que promete — As médias do efeito alocação por grupo do DGP — bem alocadas, neutras, mal alocadas — praticamente coincidem com as verdadeiras.

A inferência separa sinal de ruído — No AP, de vantagem verdadeira de 0,06%, 3 dos 4 modelos inferenciais recusam significância a 5%.

A forma dinâmica compensa volatilidade — Somar decomposições anuais reduz o erro de magnitude, e a vantagem sobre as formas estáticas cresce no cenário de estresse.

Onde ela falha

Magnitude é convenção — Mudar só o ano de ponderação abre 43,8 mil empregos de faixa no AC, 40% do valor verdadeiro.

O resíduo absorve a má alocação — No GO, com alocação de −58,2 mil, todas as 11 variantes subestimam a vantagem em 18,0 a 29,3 mil.

O nível premia tamanho — MG tem taxa de 0,12% e AC de 2,04%; em empregos os dois efeitos ficam na mesma ordem. É o defeito que E* corrige.

Duas extensões degeneram por álgebra — Em Arcelus I, DN e EM são nulos por UF; em Arcelus II, o diferencial somado é −IM, com sinal correto em só 44% das UFs.

Fora do laboratório, quase nada é significativo — Na RAIS 2022–2025, de 27 UFs apenas 0 a 4 têm efeito competitivo distinguível de zero a 5% — e uma quebra de série desloca mais que a pior escolha de variante.

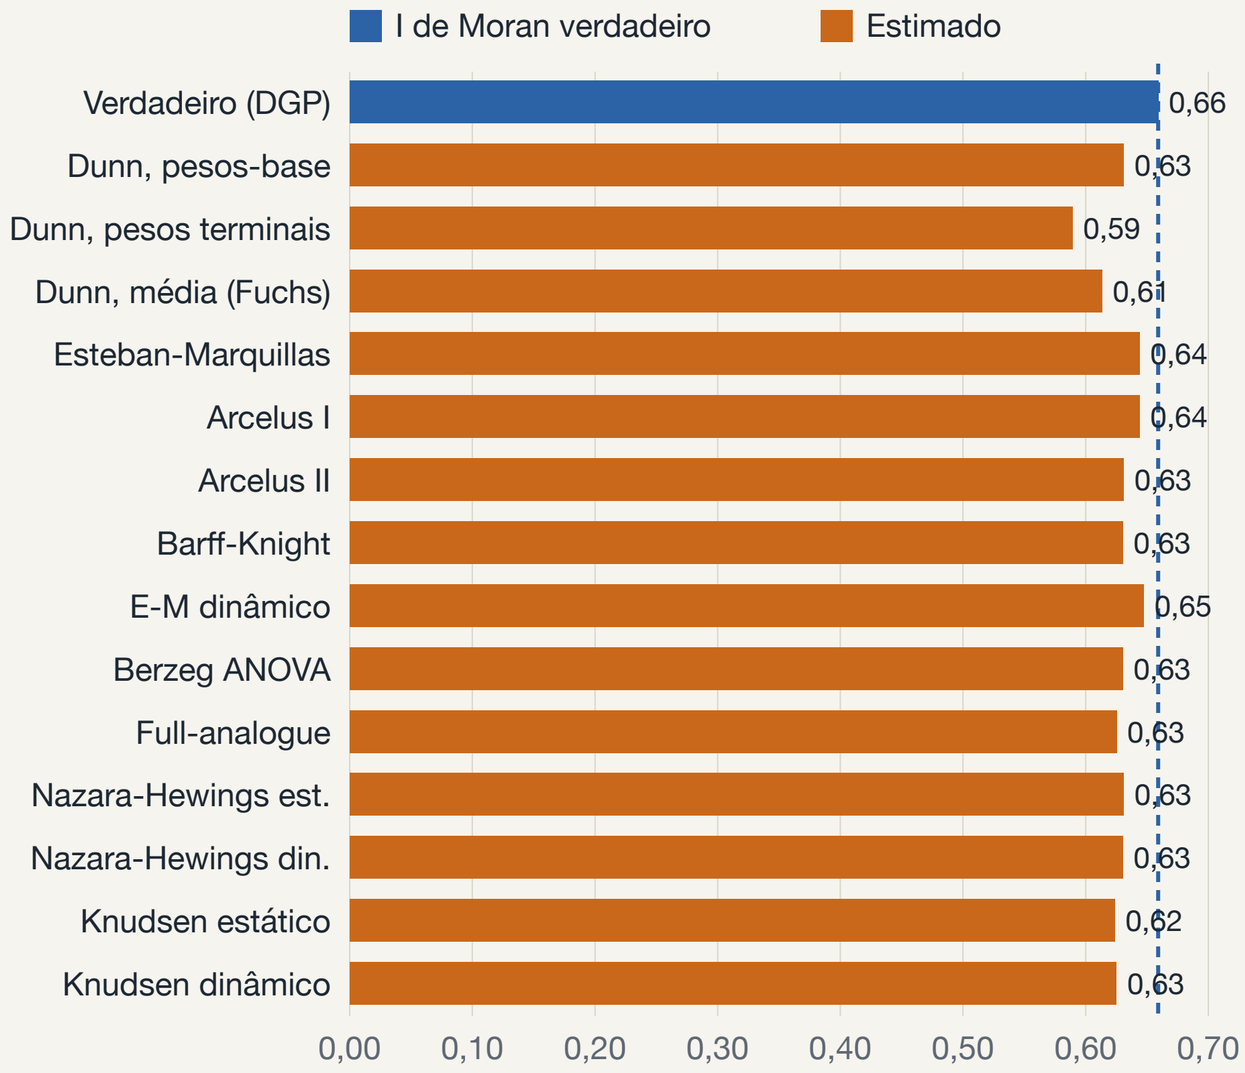
Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

DEPENDÊNCIA ESPACIAL

Todos detectam o agrupamento espacial

I de Moran das taxas competitivas: verdadeiro 0,66; estimado entre 0,59 e 0,65, todos com p = 0,001.

Calculado sobre o emprego em nível, o I cai para cerca de 0,12, não significativo: o tamanho das UFs encobre o padrão.



Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

INFERÊNCIA

Só os modelos inferenciais dizem se o efeito é real

Modelo	UFs signif. 5%	Vantagem forte	Vantagem fraca
Berzeg ANOVA	21 de 27	100%	44%
Full-analogue	20 de 27	100%	33%
Knudsen estático	16 de 27	89%	22%
Knudsen dinâmico	22 de 27	100%	44%

“Vantagem forte”: terço das UFs com maior |c̄| verdadeiro, parcela marcada como significativa (poder). “Vantagem fraca”: terço com menor |c̄|, parcela marcada mesmo assim. As variantes determinísticas produzem números sem nenhum meio de separar sinal de ruído.

Simulação semente 42 · 27 UFs × 5 setores × 10 anos · valores em mil empregos

DO LABORATÓRIO AO CAMPO

As mesmas treze variantes, agora sem gabarito

Emprego formal das 27 UFs por seção CNAE 2.0, vínculos ativos em 31/12, microdados de estabelecimentos da RAIS. De **44,1 milhões** de vínculos em 2022 para **48,7 milhões** em 2025 (10,5%).

```
ftp://ftp.mtps.gov.br/pdet/microdados/RAIS/<ano>/RAIS_ESTAB_PUB.7z → rais_uf_secao.csv
```

As três perguntas da simulação (correlação com a verdade, nRMSE, acerto de sinal) deixam de existir. Sobram as perguntas da literatura aplicada:

Concordam?

Sem verdade, resta medir a distância entre as variantes nos mesmos números.

Do que depende?

Ano de ponderação, nível de agregação setorial, integridade da série.

Há efeito?

Os modelos inferenciais conseguem distinguir alguma UF de zero?

RAIS 2022–2025 (MTE/PDET) · 27 UFs × 18 seções CNAE · valores em mil vínculos ativos

RAIS · ANTES DE DECOMPOR

A quebra de série vira efeito competitivo

Desde 2023 a RAIS vem do eSocial, e os vínculos públicos foram reclassificados: estatutários −907.224, contratos por lei municipal +927.463. É a mesma pessoa em outra caixa.

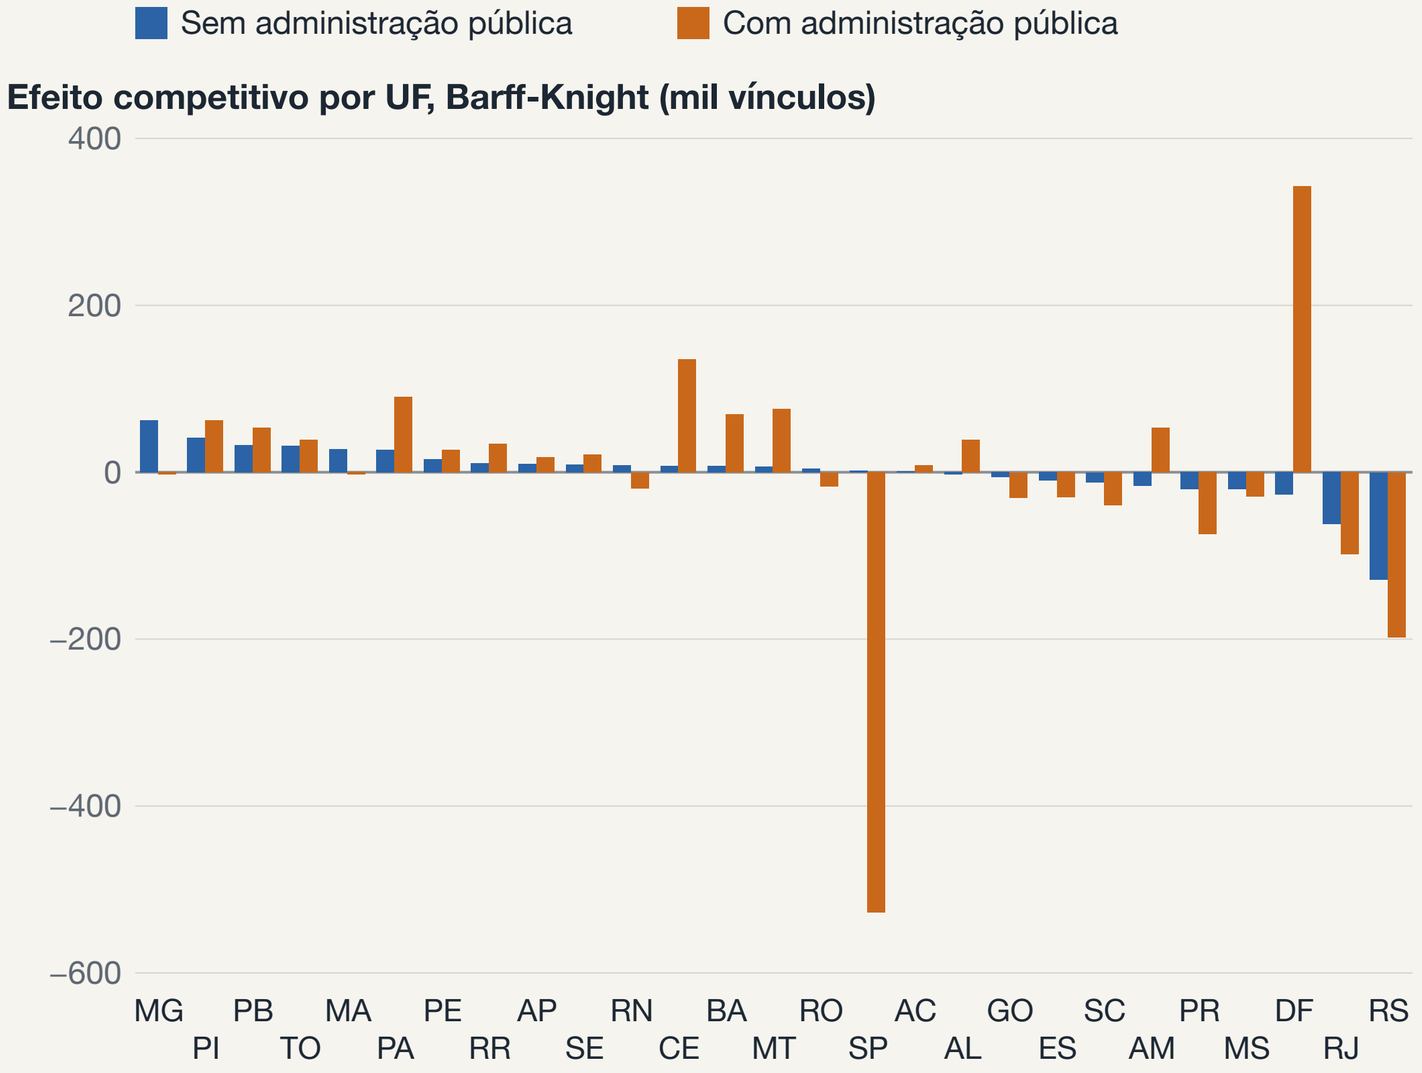
A identidade não distingue **ficou competitivo** de **passou a declarar**

0,44
Spearman entre as duas versões

3,82
nRMSE da inclusão

529
mil vínculos a menos em SP

Crescimento da seção O, 2022–2025: DF 176%, RR 110%, MT 80%, SP −9%.



RAIS 2022–2025 (MTE/PDET) · 27 UFs × 18 seções CNAE · valores em mil vínculos ativos

RAIS · A DECOMPOSIÇÃO

O efeito nacional domina; o estrutural é pequeno

Barff-Knight anual sobre 2022–2025, a variante mais defensável no Monte Carlo. Em nenhuma UF a composição chega a um quarto do efeito nacional.

```
ΔE = nacional + estrutural + competitivo
```

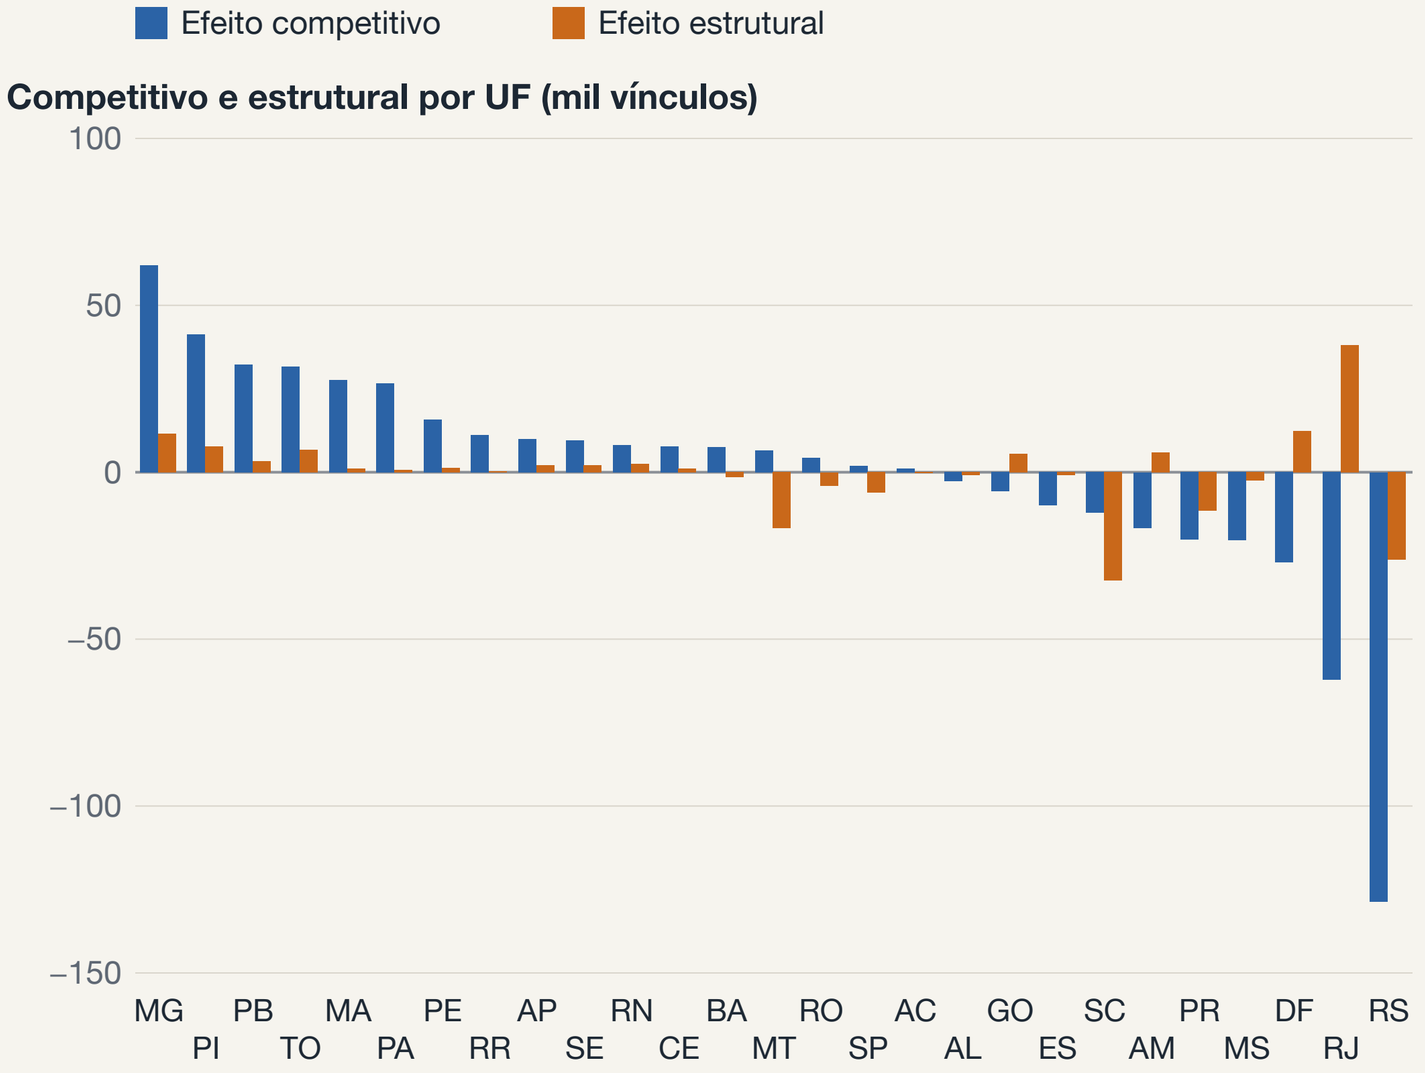
1,41
milhões de efeito nacional em SP

1,8
mil de competitivo em SP

38
maior estrutural (mil, RJ)

Ganham: MG 62, PI 41, PB 32 mil vínculos.

Perdem: RS −129, RJ −62, DF −27 mil vínculos.



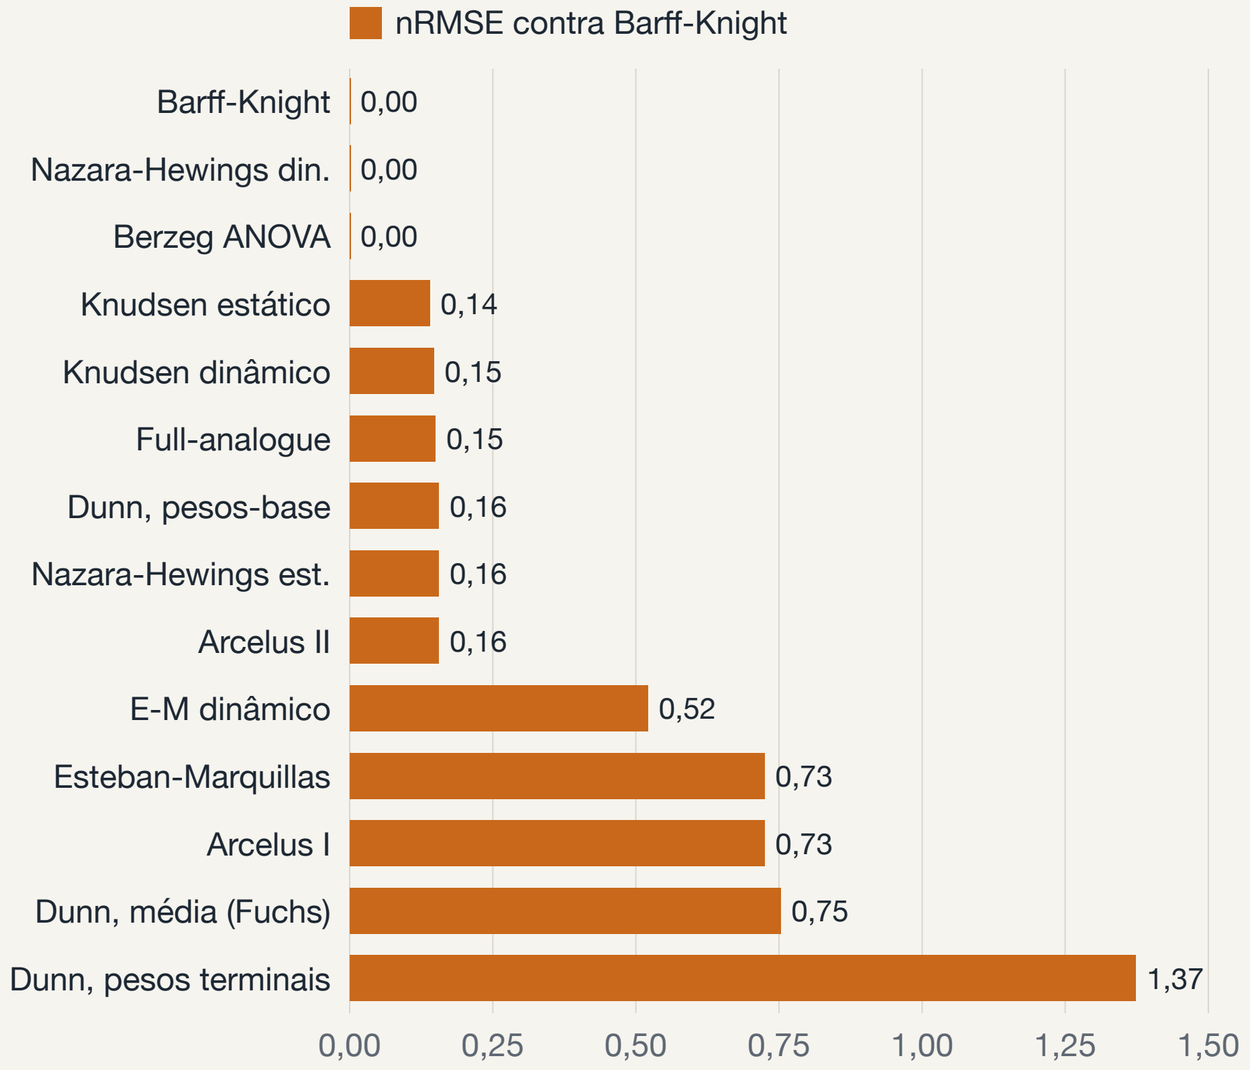
RAIS · CONCORDÂNCIA

Ordenam igual, mas discordam na magnitude

Cada variante contra a decomposição anual de Barff-Knight: RMSE da diferença dividido pelo desvio-padrão da própria referência.

Pearson entre 0,72 e 1,00 — o *ranking* das UFs quase não muda. Mas os pesos terminais discordam em 1,37 desvios-padrão e deslocam uma UF em até 15 posições de 27.

Berzeg e Nazara-Hewings dinâmico dão o mesmo competitivo total, como a aditividade exige.



RAIS 2022–2025 (MTE/PDET) · 27 UFs × 18 seções CNAE · valores em mil vínculos ativos

RAIS · AMPLITUDE

Em três UFs, o sinal é escolha do analista

Por UF, a menor e a maior estimativa do efeito competitivo entre as variantes de efeito completo. Onde o efeito é grande, a conclusão de sinal é robusta; onde é próximo de zero, não é.

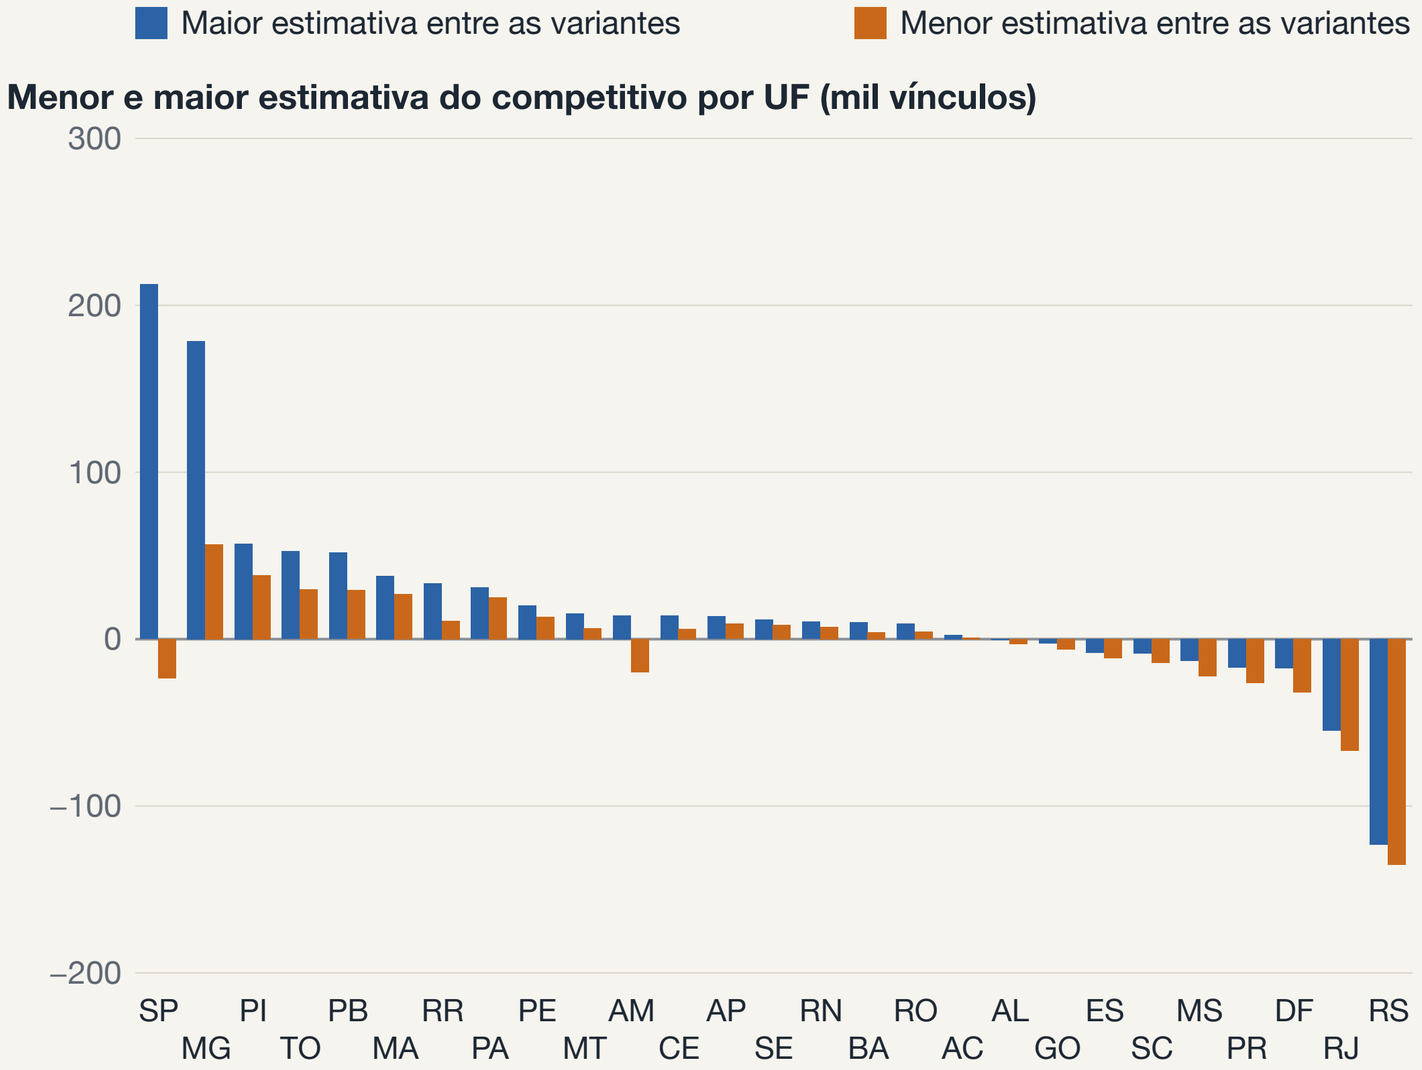
São Paulo: mediana 25,2 mil · de −23,6 a 212,6 mil

3 de 27
UFs em que o sinal muda: AL, AM, SP

236
mil vínculos de amplitude em SP

“São Paulo ganhou ou perdeu competitividade entre 2022 e 2025?” não tem resposta nestes dados: a resposta é a variante escolhida.

MG fica entre 57 e 179 mil, sempre positivo; RS, sempre bem negativo.



RAIS 2022–2025 (MTE/PDET) · 27 UFs × 18 seções CNAE · valores em mil vínculos ativos

RAIS · INFERÊNCIA

Quase nenhuma UF se distingue de zero

Modelo	UFs signif. 5%	Quais
Berzeg ANOVA	4 de 27	AP PI RS TO
Full-analogue	0 de 27	—
Knudsen estático	3 de 27	PI RS TO
Knudsen dinâmico	2 de 27	PI RS

Na simulação, estes três modelos sinalizavam 100% das UFs de vantagem forte. Nos dados reais, três anos e 18 seções deixam variação intra-UF grande o bastante para que quase todas as diferenças regionais caibam no erro-padrão.

37,5 a 57,2
mil vínculos: o competitivo do PI pelas treze variantes

2,19 a 2,41
t de Berzeg e das duas formas de Knudsen para o PI

0,98
t da regressão análoga completa para o PI

Mesmo no caso mais favorável, os métodos inferenciais não fecham entre si. Sem erro-padrão, os 27 números das variantes determinísticas parecem precisos, e não há como saber que a maioria não se distingue de zero.

RAIS 2022–2025 (MTE/PDET) · 27 UFs × 18 seções CNAE · valores em mil vínculos ativos

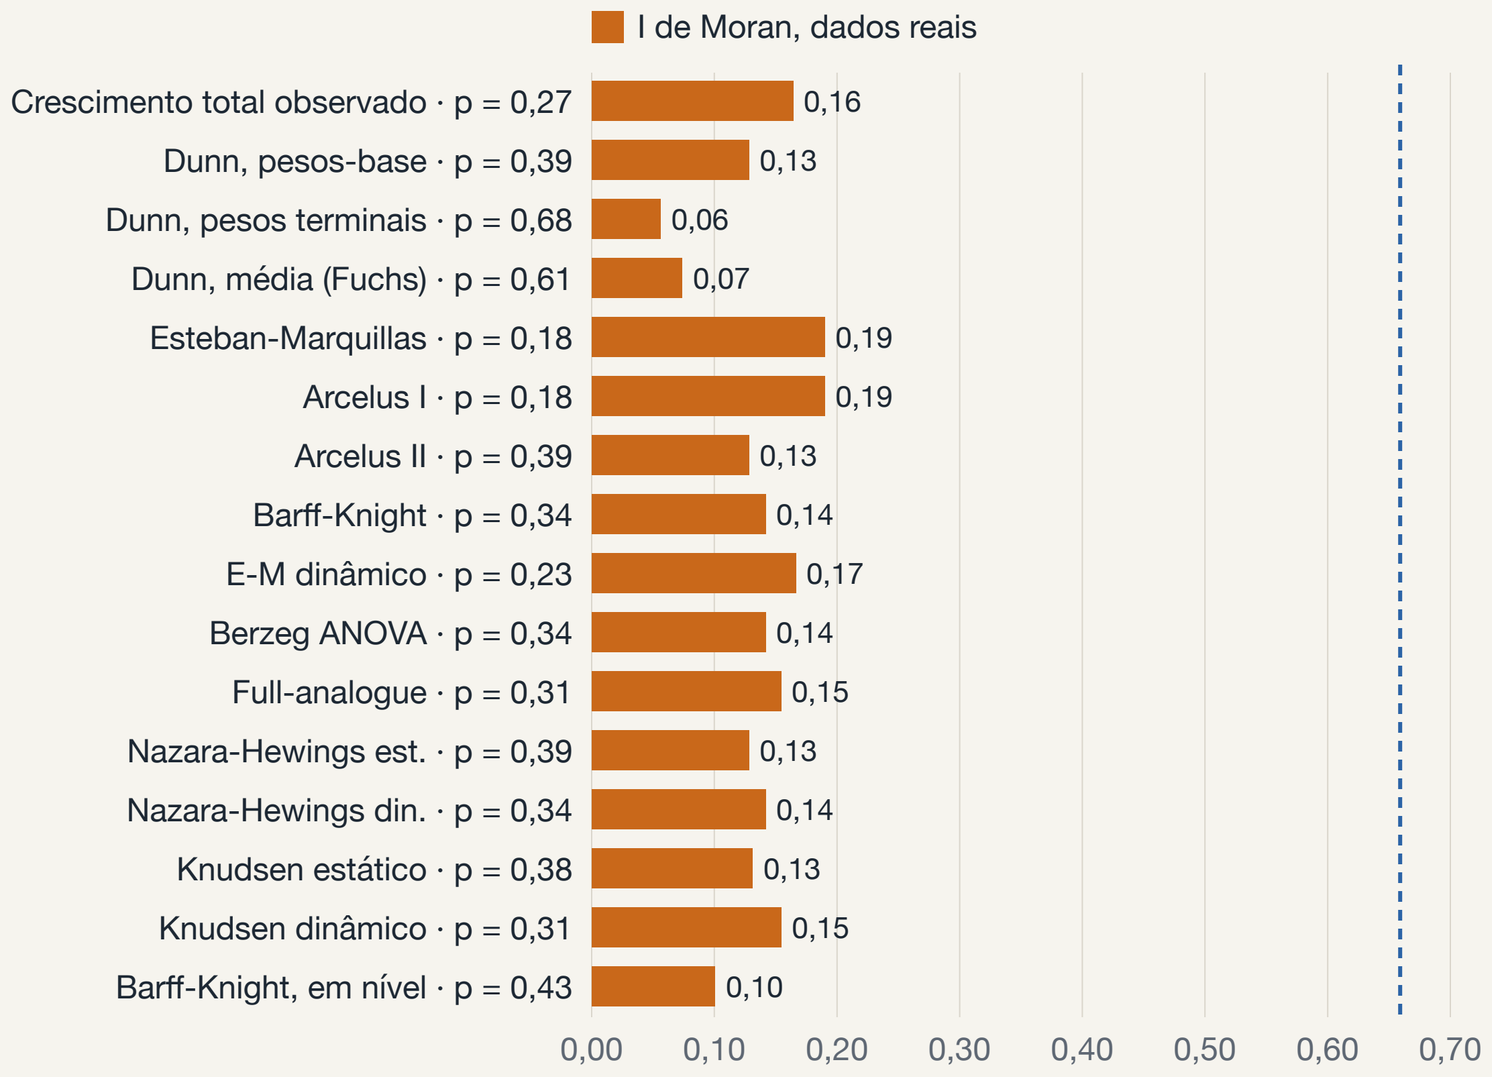
RAIS · ESPAÇO

Nazara-Hewings não se paga neste recorte

I de Moran das taxas competitivas entre 0,06 e 0,19, com p entre 0,18 e 0,68 — nenhum significativo a 10%. A linha tracejada marca o valor verdadeiro da simulação, 0,66.

A competitividade do emprego formal brasileiro não é contagiosa entre vizinhos: MG cresce bem cercado de UFs que não crescem.

A decomposição espacial continua correta — seu competitivo total é idêntico ao de Dunn — mas o componente de vizinhança não informa nada aqui.



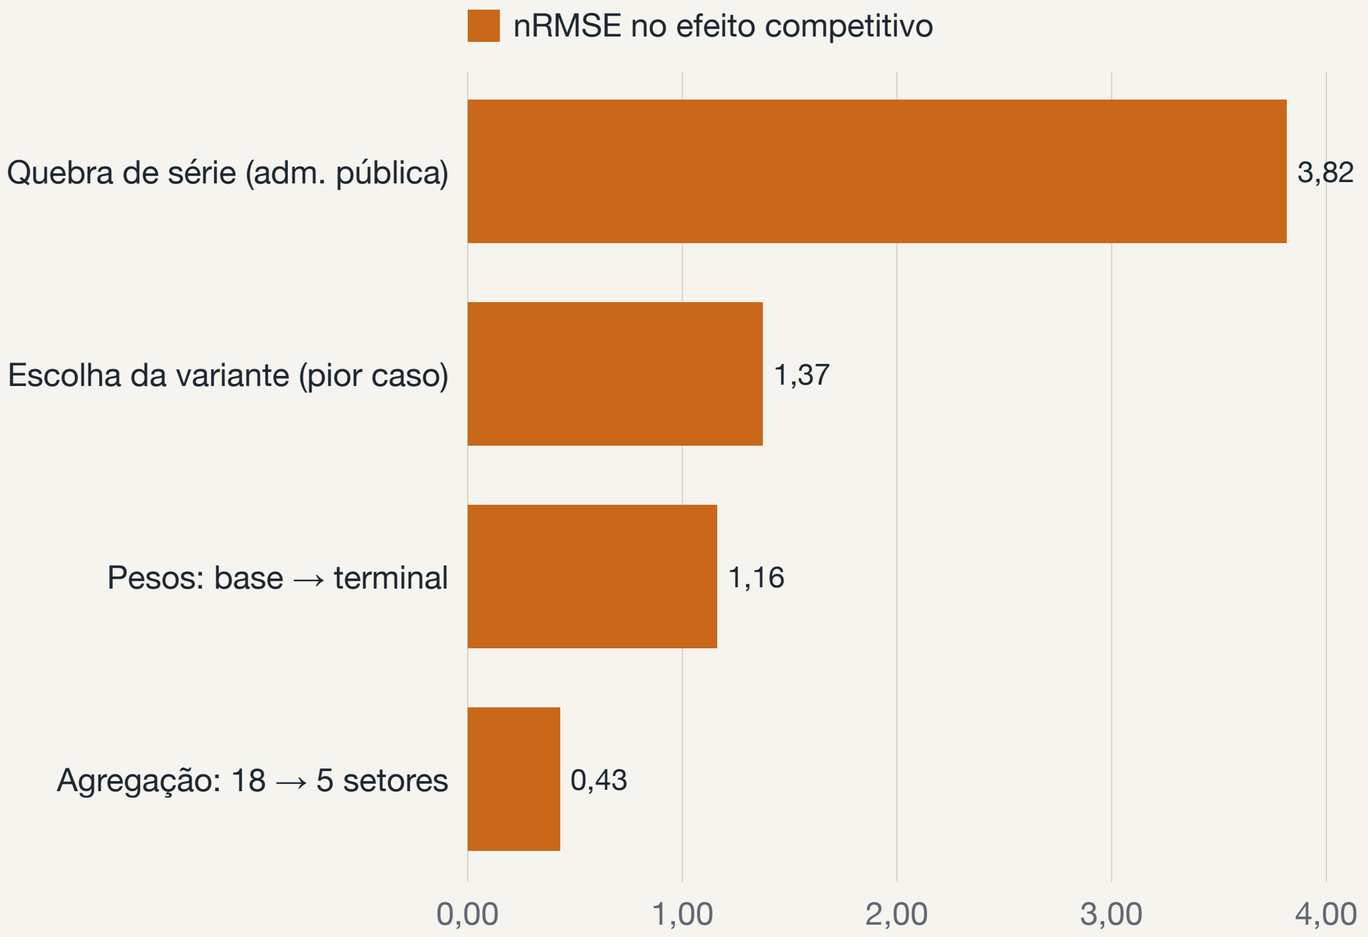
RAIS 2022–2025 (MTE/PDET) · 27 UFs × 18 seções CNAE · valores em mil vínculos ativos

A decisão mais consequente é a menos discutida

Cada barra é o nRMSE que uma escolha do analista produz no efeito competitivo, nos mesmos dados.

A integridade da série vale uma ordem de grandeza mais do que qualquer refinamento de método — e é a única das quatro que a literatura shift-share quase não discute. Não existe variante que a corrija.

Depois dela, pesos e variante, na mesma ordem de grandeza que o Monte Carlo indicava.



CONCLUSÕES

O que o laboratório e o campo dizem juntos

Ordenação robusta

Todas as variantes ordenam as UFs quase igual, na simulação (r de 0,95 a 0,99) e na RAIS (r de 0,72 a 1,00), como Knudsen e Barff (1991) previam.

Magnitude depende da forma

Formas dinâmicas e regressões ponderadas erram menos; pesos terminais erram mais, sobretudo sob volatilidade.

Alocação funciona

O efeito alocação de Esteban-Marquillas separa UFs bem e mal alocadas com médias próximas das verdadeiras.

A série vem antes do método

Na RAIS, uma quebra de série desloca o competitivo quatro vezes mais do que a pior escolha de variante — e nenhuma variante corrige isso.

Sem erro-padrão, sem resultado

Nos dados reais, de 27 UFs apenas 0 a 4 têm efeito competitivo distinguível de zero a 5%.

Limite do laboratório

A verdade da simulação é constante no tempo; na prática o efeito competitivo oscila, então aqueles resultados são um teto.

ANEXO

Quadro de parâmetros consolidados

A nota mostra *como* cada fórmula se deriva da anterior, com um exemplo pequeno o suficiente para conferir à mão; a simulação mede *quanto* cada fórmula recupera, com um painel grande o suficiente para ter poder. Significância de 5% em ambas.

Parâmetro	Nota metodológica (exemplo didático)	Simulação deste deck
Regiões	5: PI, CE, MA, BA, PE	27 unidades federativas
Setores	3: agropecuária, indústria, serviços	5 setores agregados
Períodos	$t_0 \rightarrow t_1$, dois pontos	10 anos, 9 transições anuais
Natureza dos dados	sintéticos ilustrativos, sem verdade conhecida	sintéticos com verdade embutida, semente 42
Repetições	nenhuma	50 sementes × 2 cenários
Subperíodos dinâmicos	2, trajetória hipotética	9 subperíodos anuais
Regressão de Berzeg	MQO, dummies de setor, sem ponderação	MQP nas taxas anuais, a versão que reproduz a identidade
Modelo de Knudsen	GLM Poisson, offset ln E_0, referências BA e AGR	idem, com erros quase-Poisson (dispersão ≈ 5 na forma dinâmica)
Vizinhança e I de Moran	contiguidade entre as 5 UFs, I sobre a taxa competitiva	contiguidade real das 27 UFs, rho = 0,5 no DGP, 999 permutações