Sumário

NOTA METODOLÓGICA: A EVOLUÇÃO DOS MÉTODOS DE ANÁLISE *SHIFT-SHARE* (SSA) **1**
1 INTRODUÇÃO 1
2 FUNDAMENTAÇÃO TEÓRICA 2
3 BASE DE DADOS DO EXEMPLO ILUSTRATIVO 2
4 DECOMPOSIÇÃO CLÁSSICA (DUNN, 1960) 3
5 A CONTROVÉRSIA DOS PESOS: BASE, TERMINAL E MÉDIA 4
6 A REFORMULAÇÃO HOMOTÉTICA: ESTEBAN-MARQUILLAS (1972) 5
7 A EXTENSÃO DE ARCELUS (1984) E SEUS LIMITES ALGÉBRICOS 6
8 SHIFT-SHARE DINÂMICO: BARFF-KNIGHT (1988) 8
9 FORMALIZAÇÃO INFERENCIAL: A ANOVA DE BERZEG (1978, 1984) 9
10 KNUDSEN (2000): AS DUAS FORMAS PROBABILÍSTICAS, ANOVA E TEORIA DA INFORMAÇÃO 11
11 SHIFT-SHARE ESPACIAL: NAZARA-HEWINGS (2004) 15
12 SÍNTESE: A LÓGICA DA EVOLUÇÃO METODOLÓGICA 16
13 QUADRO DE PARÂMETROS CONSOLIDADOS 17
14 LIMITAÇÕES 18
REFERÊNCIAS 19

NOTA METODOLÓGICA: A EVOLUÇÃO DOS MÉTODOS DE ANÁLISE *SHIFT-SHARE* (SSA)

Resumo — Este documento descreve, formaliza e ilustra numericamente a evolução metodológica da análise *shift-share* (SSA), da decomposição clássica de Dunn (1960) às reformulações homotéticas (Esteban-Marquillas, 1972; Arcelus, 1984), à forma dinâmica (Barff-Knight, 1988), às formalizações inferenciais (Berzeg, 1978, 1984) e à extensão espacial (Nazara-Hewings, 2004). Cada etapa é apresentada segundo o ciclo justificar–formalizar–interpretar e ilustrada com um exemplo numérico único, construído com dados sintéticos para cinco regiões e três setores, de modo que o leitor acompanhe como cada fórmula se deriva da anterior e o que cada nova camada de decomposição corrige. O documento não relata resultados de uma aplicação empírica real — define e sustenta teoricamente as escolhas de método. **Palavras-chave:** *Shift-share analysis*. Decomposição de crescimento regional. Efeito competitivo. Efeito alocação. *Shift-share* espacial.

1 INTRODUÇÃO

A análise *shift-share* (SSA) é, desde sua formulação original, uma identidade contábil que reparte a variação do emprego regional em componentes atribuíveis ao crescimento nacional, à composição setorial da região e a um resíduo dito "competitivo". Como observam Loveridge e Selting (1998), "SSA é apenas uma identidade contábil praticável: nunca pretendeu ser uma teoria" — afirmação que orienta toda a leitura deste documento. Se a SSA não é um modelo causal, o valor de cada variante está em quão bem ela isola, do resíduo, os efeitos que não deveriam nele estar: a estrutura setorial da região, o viés de ponderação temporal, a ausência de significância estatística e, mais recentemente, a dependência espacial entre regiões vizinhas.

Este documento cobre a fundamentação teórica de cada camada de reformulação, a formalização matemática associada e a tradução de cada fórmula para um exemplo numérico único e recorrente. Ele não cobre a implementação computacional das rotinas (tratada em código separado), nem pretende ser uma revisão exaustiva da literatura — para isso, ver o levantamento bibliográfico que fundamenta esta nota. O objetivo aqui é estritamente pedagógico-metodológico: mostrar, com números, *por que* cada variante surgiu e *o que* ela corrige na anterior.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 A identidade contábil e seu defeito central

A forma canônica da SSA foi sistematizada por Perloff, Dunn, Lampard e Muth (1960) e, em sua formulação de referência, por Dunn (1960), com popularização por Fuchs (1959, 1962). A decomposição clássica reparte a variação de emprego de uma região r no setor i em três parcelas aditivas: o efeito de crescimento nacional, o efeito de composição setorial (*industry mix*) e o efeito competitivo ou diferencial regional. O defeito central, identificado já por Rosenfeld (1959) e Houston (1967) e formalizado por Esteban-Marquillas (1972), é que o efeito competitivo clássico é ponderado pelo nível de emprego observado da região no setor — de modo que duas regiões com taxas de crescimento idênticas, mas estruturas setoriais distintas, recebem efeitos competitivos diferentes. O componente que deveria medir "vantagem competitiva pura" está, portanto, contaminado por estrutura produtiva. Essa contaminação motiva diretamente a Seção 6 (Esteban-Marquillas) e a Seção 7 (Arcelus) adiante.

2.2 As três ondas de reformulação

A literatura pós-1960 pode ser lida em três ondas, cada uma corrigindo uma falha diferente da identidade clássica. A primeira onda é homotética/alocativa (Esteban-Marquillas, 1972; Herzog e Olsen, 1977; Arcelus, 1984; Haynes e Machunda, 1987) e ataca a contaminação estrutural do efeito competitivo. A segunda onda é temporal/dinâmica (Fuchs, 1959; Stilwell, 1969; Barff e Knight, 1988) e ataca o viés de escolha do ano de ponderação e a distorção de crescimento composto em decomposições estáticas de ponto a ponto. A terceira onda é inferencial (Berzeg, 1978, 1984; Patterson, 1991; Knudsen, 2000) e ataca a impossibilidade de testar estatisticamente uma identidade determinística. A extensão espacial de Nazara e Hewings (2004), tratada na Seção 11, é posterior às três e ataca um pressuposto implícito em todas elas: o de que regiões vizinhas não interagem. Entre a onda inferencial e a espacial, a Seção 10 aprofunda a própria onda inferencial: Knudsen (2000) mostra que a formalização estatística da SSA não precisa se limitar ao modelo linear de Berzeg, podendo ser derivada da teoria da informação pelo princípio de mínima informação discriminante, o que leva a um modelo log-linear estimado por máxima verossimilhança como um modelo linear generalizado de Poisson. As seções 4 a 11 seguem exatamente essa ordem histórica e lógica.

3 BASE DE DADOS DO EXEMPLO ILUSTRATIVO

Para tornar cada fórmula tangível, este documento usa **um único conjunto de dados sintéticos**, reaproveitado em todas as seções seguintes, com $R = 5$ regiões (unidades federativas do Nordeste brasileiro, escolhidas por terem fronteiras terrestres reais entre si — relevante para a Seção 11) e $N = 3$ setores agregados. As regiões são Piauí (PI), Ceará (CE), Maranhão (MA), Bahia (BA) e Pernambuco (PE); os setores são Agropecuária (AGR), Indústria (IND) e Serviços (SER). Os valores de emprego são **inteiramente hipotéticos** — não correspondem a estatísticas oficiais — e foram construídos para exibir, de forma didática, um caso de vantagem competitiva concentrada em serviços (PI), um caso de forte crescimento industrial idiossincrático (CE), um caso de desvantagem competitiva generalizada (MA), um caso "neutro" próximo à média nacional em todas as taxas (BA) e um caso de especialização mal alocada (PE).

Seja $E_{0,ri}$ o emprego da região r no setor i no ano-base t_0 e $E_{1,ri}$ o emprego no ano-terminal t_1. A Tabela 1 apresenta os dados-base e a Tabela 2, o ano terminal.

Tabela 1 — Emprego por região e setor, ano-base ($E_{0,ri}$)

Região	AGR	IND	SER	Total
PI	180	90	230	500
CE	150	220	430	800
MA	200	70	180	450
BA	260	310	560	1.130
PE	140	280	520	940
Nacional	**930**	**970**	**1.920**	**3.820**

Fonte: dados sintéticos ilustrativos, elaboração própria.

Tabela 2 — Emprego por região e setor, ano-terminal ($E_{1,ri}$)

Região	AGR	IND	SER	Total
PI	189	103	322	614
CE	158	279	559	996
MA	200	77	225	502
BA	273	356	728	1.357
PE	158	322	650	1.130
Nacional	**978**	**1.137**	**2.484**	**4.599**

Fonte: dados sintéticos ilustrativos, elaboração própria.

Dessas duas tabelas derivam-se as três taxas de crescimento que alimentam toda a análise subsequente: a taxa regional-setorial $g_{ri} = (E_{1,ri} - E_{0,ri})/E_{0,ri}$, a taxa nacional do setor $g_{ni} = (\sum_r E_{1,ri} - \sum_r E_{0,ri})/\sum_r E_{0,ri}$ e a taxa nacional agregada $g_n = (\sum_{r,i} E_{1,ri} - \sum_{r,i} E_{0,ri})/\sum_{r,i} E_{0,ri}$. Neste exemplo, $g_n = 20{,}39\%$, e as taxas nacionais setoriais são $g_{n,\text{AGR}} = 5{,}16\%$, $g_{n,\text{IND}} = 17{,}22\%$ e $g_{n,\text{SER}} = 29{,}38\%$ — um padrão de terciarização nacional que será a "ponta" contra a qual cada região é comparada.

Tabela 3 — Taxa de crescimento regional-setorial g_{ri} (%)

Região	AGR	IND	SER
PI	5,00	14,44	40,00
CE	5,33	26,82	30,00
MA	0,00	10,00	25,00
BA	5,00	14,84	30,00
PE	12,86	15,00	25,00

Fonte: elaboração própria a partir das Tabelas 1 e 2.

4 DECOMPOSIÇÃO CLÁSSICA (DUNN, 1960)

A forma canônica, sistematizada por Perloff, Dunn, Lampard e Muth (1960) a partir de precursores como o Barlow Report de 1940 e Creamer (1943), reparte a variação absoluta de emprego $\Delta E_{ri} = E_{1,ri} - E_{0,ri}$ em três parcelas aditivas, todas ponderadas pelo emprego-base $E_{0,ri}$:

$$\Delta E_{ri} = \underbrace{E_{0,ri}\, g_n}_{NE_{ri}} + \underbrace{E_{0,ri}\,(g_{ni} - g_n)}_{IM_{ri}} + \underbrace{E_{0,ri}\,(g_{ri} - g_{ni})}_{CE_{ri}} \tag{1}$$

em que NE_{ri} é o **efeito de crescimento nacional** (o quanto a região teria crescido se cada setor acompanhasse exatamente a taxa agregada do país), IM_{ri} é o **efeito de composição setorial** (crescimento extra ou perdido por a região estar voltada a setores nacionalmente mais ou menos dinâmicos que a média) e CE_{ri} é o **efeito competitivo ou diferencial regional** (o resíduo: quanto a região cresceu acima ou abaixo do que seu próprio setor cresceu no país). A soma $NE_{ri} + IM_{ri}$ é o crescimento "esperado" da região; CE_{ri} é o desvio ("*shift*") dessa expectativa — o que dá nome ao método (SELTING; LOVERIDGE, 1992).

A Tabela 4 aplica a Equação 1 aos dados das Tabelas 1–3. Note que a soma das três colunas, célula a célula, reproduz exatamente ΔE_{ri} — a identidade é algébrica, não estatística, e vale à precisão de máquina.

Tabela 4 — Decomposição clássica de Dunn (1960): totais regionais

Região	ΔE_r	NE_r	IM_r	CE_r
PI	114	101,96	−9,62	21,65
CE	196	163,14	8,79	24,07
MA	52	91,77	−16,52	−23,25
BA	227	230,44	0,85	−4,29
PE	190	191,69	16,49	−18,18

Fonte: elaboração própria, Equação 1 aplicada às Tabelas 1–3.

A leitura já revela o problema que motivou toda a literatura subsequente. Piauí e Ceará têm efeitos competitivos positivos e de magnitude parecida (21,65 e 24,07), mas por razões distintas: o Ceará deve seu resultado principalmente à indústria (crescimento setorial de 26,82% contra 17,22% nacional), enquanto o Piauí deve o seu quase inteiramente a serviços (40% contra 29,38% nacional). O componente CE_r, por si só, não distingue essas duas histórias — nem informa se o desempenho vem de um setor em que a região é fortemente especializada ou de um setor marginal em sua estrutura. Essa é exatamente a lacuna que Esteban-Marquillas (1972) endereça na Seção 6.

5 A CONTROVÉRSIA DOS PESOS: BASE, TERMINAL E MÉDIA

Fuchs (1959) mostrou que o efeito competitivo é relativamente pouco sensível à escolha do ano de ponderação, mas o efeito de composição setorial é sensível — e propôs a **média entre pesos-base e pesos-terminais** como correção. Stilwell (1969) propôs o extremo oposto, uma "composição reversa" com pesos exclusivamente terminais, para sinalizar regiões em declínio; Ashby (1970) criticou essa escolha como excessiva, defendendo uma convenção intermediária "cinquenta-cinquenta". A escolha do ano de ponderação, portanto, não é uma decisão neutra — é uma escolha teórica sobre qual estrutura produtiva (a de partida ou a de chegada) deve servir de referência para julgar o desempenho da região.

Para reponderar pelo ano terminal preservando a identidade aditiva, define-se a taxa "reversa" $g'_{ri} = (E_{0,ri} - E_{1,ri})/E_{1,ri}$ — o crescimento de t_1 para t_0 — e repete-se a Equação 1 usando $E_{1,ri}$ como peso e g' no lugar de g:

$$E_{0,ri} - E_{1,ri} = E_{1,ri}\, g'_n + E_{1,ri}\,(g'_{ni} - g'_n) + E_{1,ri}\,(g'_{ri} - g'_{ni}) \tag{2}$$

Como o lado esquerdo da Equação 2 é $-\Delta E_{ri}$, basta inverter o sinal de cada componente para obter a decomposição terminal na mesma unidade da Equação 1. A Tabela 5 compara o efeito competitivo sob pesos-base (Equação 1) e sob pesos-terminais (Equação 2, sinal invertido).

Tabela 5 — Sensibilidade do efeito competitivo à escolha do ano de ponderação

Região	CE_r (peso-base)	CE_r (peso-terminal)	Diferença
PI	21,65	16,48	−5,17
CE	24,07	20,34	−3,73
MA	−23,25	−20,21	3,04
BA	−4,29	−3,98	0,31
PE	−18,18	−12,63	5,55

Fonte: elaboração própria, Equações 1 e 2.

O efeito competitivo muda de magnitude, mas não de sinal, em todas as cinco regiões deste exemplo — confirmando, nesta escala reduzida, o achado de Fuchs (1959) de relativa estabilidade de sinal do componente competitivo clássico. O mesmo não ocorrerá com o efeito de alocação de Esteban-Marquillas, como mostra a Seção 6.3 adiante — e é justamente essa diferença de comportamento sob reponderação que torna a crítica de Herzog e Olsen (1977) empiricamente relevante.

6 A REFORMULAÇÃO HOMOTÉTICA: ESTEBAN-MARQUILLAS (1972)

6.1 Justificativa

Esteban-Marquillas (1972) demonstrou formalmente o problema já apontado por Rosenfeld (1959): como CE_{ri} na Equação 1 é ponderado pelo emprego efetivamente observado $E_{0,ri}$, duas regiões com a mesma taxa diferencial $(g_{ri} - g_{ni})$ recebem efeitos competitivos absolutos diferentes apenas porque uma delas tem mais peso naquele setor — o componente mistura, portanto, "quanto a região é competitiva" com "quanto emprego ela tem para multiplicar essa competitividade". A solução proposta foi substituir o peso observado por um peso contrafactual: o emprego que a região *teria* no setor se sua estrutura produtiva reproduzisse exatamente as participações setoriais nacionais.

6.2 Formalização

Define-se o **emprego homotético**:

$$E^*_{ri} = E_{0,r\bullet}\left(\frac{E_{0,\bullet i}}{E_{0,\bullet\bullet}}\right) \tag{3}$$

em que $E_{0,r\bullet} = \sum_i E_{0,ri}$ é o total regional, $E_{0,\bullet i} = \sum_r E_{0,ri}$ é o total nacional do setor i e $E_{0,\bullet\bullet}$ é o total nacional. E^*_{ri} é, portanto, o total de emprego da região distribuído segundo as participações setoriais do país — a estrutura que a região teria se fosse uma miniatura fiel da economia nacional. O efeito competitivo clássico da Equação 1 é então reescrito como a soma de dois termos:

$$CE_{ri} = \underbrace{E^*_{ri}\,(g_{ri} - g_{ni})}_{CE^*_{ri}\ \text{(competitivo puro)}} + \underbrace{(E_{0,ri} - E^*_{ri})\,(g_{ri} - g_{ni})}_{AE_{ri}\ \text{(efeito alocação)}} \tag{4}$$

CE^*_{ri} é o efeito competitivo **livre de estrutura** — mede apenas a diferença de taxa, ponderada pelo emprego "neutro" E^*. AE_{ri}, o **efeito alocação**, é o produto entre o grau de especialização da região no setor ($E_{0,ri} - E^*_{ri}$, positivo se a região é mais especializada que a média nacional naquele setor) e a vantagem competitiva nesse mesmo setor $(g_{ri} - g_{ni})$. AE_{ri} é positivo quando a região se especializa exatamente nos setores em que também é competitiva (alocação "correta") e negativo quando ela se especializa em setores nos quais tem desvantagem, ou deixa de se especializar em setores nos quais tem vantagem (alocação "incorreta" ou subotimizada).

6.3 Aplicação e interpretação

A Tabela 6 traz o emprego homotético (Equação 3); a Tabela 7, a decomposição de Esteban-Marquillas (Equação 4) em totais regionais, ao lado da decomposição clássica para comparação.

Tabela 6 — Emprego homotético E^*_{ri}

Região	AGR	IND	SER
PI	121,73	126,96	251,31
CE	194,76	203,14	402,09
MA	109,55	114,27	226,18
BA	275,10	286,94	567,96
PE	228,85	238,69	472,46

Fonte: elaboração própria, Equação 3.

Tabela 7 — Decomposição de Esteban-Marquillas (1972): totais regionais

Região	NE_r	IM_r	CE_r (clássico)	CE_r^* (puro)	AE_r (alocação)
PI	101,96	−9,62	21,65	22,99	−1,33
CE	163,14	8,79	24,07	22,35	1,72
MA	91,77	−16,52	−23,25	−23,80	0,55
BA	230,44	0,85	−4,29	−3,72	−0,57
PE	191,69	16,49	−18,18	−8,35	−9,83

Fonte: elaboração própria, Equação 4. Note que $CE_r^* + AE_r = CE_r$ (clássico) em cada linha, confirmando a Equação 4.

O caso de Pernambuco ilustra exatamente o que a reformulação foi desenhada para revelar. Na decomposição clássica (Tabela 4), PE tinha um efeito competitivo de −18,18 — número que, isoladamente, sugere fraco desempenho competitivo generalizado. A Tabela 7 mostra que isso é impreciso: o efeito competitivo *puro* de PE é de apenas −8,35 (metade do valor clássico), e o restante, −9,83, é efeito de **má alocação**: PE tem vantagem competitiva forte em Agropecuária ($g_{ri} - g_{ni} = +7,70$ pontos percentuais) mas está *sub*-especializado nesse setor ($E_{0,ri} - E_{ri}^* = -88,85$, ou seja, emprega menos em Agropecuária do que sua estrutura homotética previria) — a região não está capturando um ganho que sua própria vantagem comparativa permitiria. Já Piauí e Ceará mostram exatamente o padrão oposto: seus efeitos de alocação são pequenos (−1,33 e +1,72), o que indica que a maior parte do desempenho observado nessas duas regiões é competitividade genuína, não um acidente de composição setorial.

7 A EXTENSÃO DE ARCELUS (1984) E SEUS LIMITES ALGÉBRICOS

7.1 Justificativa

Arcelus (1984) argumentou que Esteban-Marquillas não "explorou suficientemente" a propriedade do emprego homotético, restringindo-a ao efeito competitivo. Sua proposta foi aplicar a mesma lógica de decomposição — separar um termo "esperado" (ponderado por E^*) de um termo "diferencial" (ponderado por $E_{0,ri} - E_{ri}^*$) — também ao efeito de crescimento nacional e ao efeito de composição setorial, produzindo quatro subcomponentes em vez de dois.

7.2 Formalização

Aplicando a mesma partição da Equação 4 aos dois primeiros termos da Equação 1:

$$NE_{ri} = \underbrace{E_{ri}^* \, g_n}_{EN_{ri}} + \underbrace{(E_{0,ri} - E_{ri}^*) \, g_n}_{DN_{ri}} \qquad IM_{ri} = \underbrace{E_{ri}^* \, (g_{ni} - g_n)}_{EM_{ri}} + \underbrace{(E_{0,ri} - E_{ri}^*) \, (g_{ni} - g_n)}_{DM_{ri}} \tag{5}$$

7.3 Uma propriedade algébrica que qualifica a extensão

Somando a Equação 5 sobre os setores i de uma mesma região r, duas propriedades emergem diretamente da definição de E^* na Equação 3: primeiro, $\sum_i (E_{0,ri} - E_{ri}^*) \equiv 0$ para qualquer região, porque o emprego homotético é construído para preservar exatamente o total regional ($\sum_i E_{ri}^* = E_{0,r\bullet}$); segundo, $\sum_i E_{ri}^* (g_{ni} - g_n) \equiv 0$ para qualquer região, porque os pesos $E_{ri}^* / E_{0,r\bullet}$ reproduzem exatamente as participações setoriais nacionais, e a média nacional ponderada por essas participações é, por definição, g_n. Segue que, somados por região, $DN_r \equiv 0$ e $EM_r \equiv 0$ **identicamente**, para qualquer conjunto de dados — não é um resultado deste exemplo específico, mas uma propriedade algébrica da construção. A Tabela 8 confirma isso numericamente.

Tabela 8 — Arcelus I (Equação 5): totais regionais

Região	EN_r	DN_r	EM_r	DM_r	CE_r^*	AE_r
PI	101,96	0,00	0,00	−9,62	22,99	−1,33
CE	163,14	0,00	0,00	8,79	22,35	1,72

Região	EN_r	DN_r	EM_r	DM_r	CE^*_r	AE_r
MA	91,77	0,00	0,00	−16,52	−23,80	0,55
BA	230,44	0,00	0,00	0,85	−3,72	−0,57
PE	191,69	0,00	0,00	16,49	−8,35	−9,83

Fonte: elaboração própria, Equação 5.

Em outras palavras: ao nível regional agregado (a soma sobre setores), a homotetização de NE e IM não produz informação nova — EN_r reproduz NE_r e DM_r reproduz IM_r da Tabela 4, célula a célula. O ganho analítico da homotetização, como Esteban-Marquillas já havia percebido, está concentrado no efeito competitivo, onde $(g_{ri} - g_{ni})$ varia célula a célula e não se anula ao somar. Esse resultado algébrico é consistente com — e ajuda a explicar — o achado empírico de Keil (1992), que, usando dados de Indiana (1977–1986), concluiu que as extensões homotéticas de Esteban-Marquillas e Arcelus "lançam pouca luz sobre o crescimento regional total" mesmo quando esclarecem taxas de indústrias individuais: o próprio arcabouço algébrico garante que dois dos quatro novos subcomponentes de Arcelus sejam nulos quando agregados por região. Arcelus (1984) propôs ainda um segundo modelo (Arcelus II), que não parte do emprego homotético, mas da taxa de crescimento *da própria região* como referência adicional; é a variante formalizada na Seção 7.4.

7.4 Arcelus II: deslocamento regional e deslocamento diferencial

O segundo modelo de Arcelus (1984) ataca um problema diferente do da Seção 7.2. Ali, a referência contra a qual cada célula é avaliada continua sendo nacional, e o que muda é o ponderador, substituído pelo emprego homotético. Aqui, o que muda é a própria referência: parte do desempenho de uma célula pode decorrer de a região inteira estar crescendo acima ou abaixo do país, e não de uma vantagem no setor i especificamente. O modelo separa esses dois níveis, acrescentando à identidade de Dunn um **deslocamento regional** e um **deslocamento diferencial**, medido contra a taxa da própria região.

Seja $g_r = (\sum_i E_{1,ri} - \sum_i E_{0,ri}) / \sum_i E_{0,ri}$ a taxa de crescimento agregada da região r. A identidade passa a ter quatro termos:

$$\Delta E_{ri} = \underbrace{E_{0,ri}\, g_n}_{n_{ri}} + \underbrace{E_{0,ri}\,(g_{ni} - g_n)}_{s_{ri}} + \underbrace{E_{0,ri}\,(g_r - g_n)}_{r_{ri}} + \underbrace{E_{0,ri}\,[(g_{ri} - g_r) - (g_{ni} - g_n)]}_{d_{ri}} \tag{6}$$

em que n_{ri} e s_{ri} são o crescimento nacional e a composição setorial da Equação 1, inalterados; r_{ri} é o **deslocamento regional**, o quanto a célula se move por a região como um todo crescer acima ou abaixo do país; e d_{ri} é o **deslocamento diferencial**, o quanto o setor i se destaca *dentro* da região, líquido do que esse mesmo setor se destaca dentro do país. A soma dos quatro termos recupera $E_{0,ri}\, g_{ri} = \Delta E_{ri}$: os termos g_n, g_{ni} e g_r se cancelam dois a dois, e a identidade fecha à precisão de máquina, como a de Dunn.

A relação com as Seções 4 e 7.2 é direta e vale célula a célula:

$$r_{ri} + d_{ri} = E_{0,ri}\,(g_{ri} - g_{ni}) = CE_{ri} \tag{7}$$

Ou seja: **Arcelus II é uma partição do efeito competitivo de Dunn**, que ele reparte entre um componente de desempenho da região inteira e um componente de desempenho setorial líquido. Arcelus I, por contraste, não toca no competitivo total — ele repondera os componentes nacional e de composição pelo emprego homotético. São dois objetos distintos, e a confusão entre eles tem consequência prática, discutida na Seção 10.1: a "extensão de Arcelus" a que Knudsen (2000) recorre para construir suas formas probabilísticas é esta, a da Equação 6, não a da Equação 5.

Somando a Equação 6 sobre os setores de uma mesma região, emerge uma propriedade algébrica análoga à da Seção 7.3, e igualmente desfavorável à extensão. Como g_r é, por construção, a taxa que reproduz o total da região, vale $\sum_i E_{0,ri}(g_{ri} - g_r) \equiv 0$, e portanto:

$$d_r \equiv -\,IM_r, \qquad r_r \equiv IM_r + CE_r, \qquad \sum_r r_r \equiv 0 \tag{8}$$

para qualquer conjunto de dados. Ao nível regional agregado, portanto, o deslocamento diferencial não é informação nova: é o efeito de composição setorial da Tabela 4 com o sinal trocado. E o deslocamento regional é a soma dos efeitos de composição e competitivo, isto é, todo o desvio da região em relação ao crescimento nacional. A Tabela 9 confirma as três identidades numericamente. A consequência prática aparece na simulação de 27 unidades federativas do projeto, cujo processo gerador constrói a taxa competitiva como $c_{ri} = \bar{c}_r + d_{ri}$ e portanto oferece gabarito separado para os dois deslocamentos: o deslocamento regional estimado recupera a vantagem verdadeira da região com correlação de 0,84, enquanto o diferencial, somado por região, tem correlação de −0,20, nRMSE de 1,16 e sinal correto em 44% das unidades — desempenho pior que o de chutar a média, exatamente como a identidade $d_r \equiv -IM_r$ prevê.

Tabela 9 — Arcelus II (Equação 6): totais regionais

Região	n_r	s_r	r_r	d_r	$r_r + d_r$	CE_r (Tab. 4)
PI	101,96	−9,62	12,04	9,62	21,65	21,65
CE	163,14	8,79	32,86	−8,79	24,07	24,07
MA	91,77	−16,52	−39,77	16,52	−23,25	−23,25
BA	230,44	0,85	−3,44	−0,85	−4,29	−4,29
PE	191,69	16,49	−1,69	−16,49	−18,18	−18,18

Fonte: elaboração própria, Equação 6 aplicada às Tabelas 1–3.

A leitura substantiva, ainda assim, difere da de Dunn. Piauí e Ceará têm efeitos competitivos quase iguais (21,65 e 24,07), mas Arcelus II mostra que eles vêm de fontes opostas: no Ceará, o deslocamento regional (32,86) mais do que explica o total, e o diferencial o puxa para baixo (−8,79) — é um estado crescendo acima do país em bloco, não por um setor; no Piauí, o deslocamento regional é modesto (12,04) e quase metade do resultado é deslocamento diferencial (9,62), concentrado em serviços. Maranhão é o inverso simétrico do Ceará: um deslocamento regional fortemente negativo (−39,77) parcialmente compensado por um diferencial positivo. Essa é exatamente a distinção que a Seção 4 apontou como ausente no CE_r de Dunn — e que Esteban-Marquillas responde por outro caminho, o da especialização.

Procedência da formalização. O artigo original de Arcelus (1984) não foi consultado diretamente. A Equação 6 reproduz as equações 2, 2a, 2b e 2c de Knudsen (2000, p. 179), que apresenta essa identidade de quatro termos como "a extensão de Arcelus" e a credita a Arcelus (1984, *Growth and Change* 15:3–8) na referência [23] de sua lista. Trata-se, portanto, de uma fonte secundária, mas com a álgebra explícita e verificável — e verificada aqui, pelo fechamento da identidade e pelas três propriedades da Equação 8. Duas ressalvas. Primeira: as equações 1a–1c e 2a–2b aparecem impressas em Knudsen (2000) com $\acute{E}_i^r$, o emprego do **ano terminal**, como ponderador; com esses pesos a soma dos componentes dá $E_{1,ri}\, g_{ri}$, e não ΔE_{ri}, de modo que a identidade não fecha. Esta nota adota $E_{0,ri}$, coerente com a Equação 1 e com a prática corrente. Segunda: Arcelus (1984) descreve seu segundo modelo em termos de efeitos de crescimento e de composição *regionais*; a correspondência desses nomes com r_{ri} e d_{ri} é a leitura natural da álgebra, mas não foi conferida contra a nomenclatura do original. Antes de qualquer uso formal, recomenda-se a consulta direta à fonte primária.

8 SHIFT-SHARE DINÂMICO: BARFF-KNIGHT (1988)

8.1 Justificativa

Todas as decomposições até aqui são "estáticas comparativas": comparam apenas os pontos t_0 e t_1, ignorando a trajetória entre eles. Barff e Knight (1988), retomando uma sugestão de Thirlwall (1967) de particionar o período em subperíodos, argumentaram que essa comparação de extremos é distorcida por crescimento composto e por mudanças na composição setorial *durante* o intervalo — um setor pode crescer rapidamente no início do período e desacelerar no fim (ou vice-versa) sem que a taxa ponta a ponta capture essa dinâmica.

8.2 Formalização

Particiona-se o intervalo $[t_0, t_1]$ em K subperíodos. Para cada subperíodo k, calcula-se a decomposição clássica (Equação 1) usando o emprego do início do subperíodo como peso-base; o efeito competitivo dinâmico é a soma dos efeitos competitivos de cada subperíodo:

$$CE_{ri}^{\text{din}} = \sum_{k=1}^{K} E_{k-1,ri} \left(g_{ri}^{(k)} - g_{ni}^{(k)} \right) \tag{9}$$

em que $g_{ri}^{(k)}$ e $g_{ni}^{(k)}$ são as taxas regional-setorial e nacional-setorial calculadas apenas dentro do subperíodo k, com peso-base $E_{k-1,ri}$ (o emprego no início daquele subperíodo, não o do início do período total). Compara-se CE_{ri}^{din} ao efeito competitivo estático CE_{ri}^{est} (Equação 1, aplicada diretamente a t_0 e t_1) para medir a magnitude da distorção de trajetória.

8.3 Aplicação

Para ilustrar, o intervalo $[t_0, t_1]$ foi dividido em dois subperíodos ($K = 2$) com uma trajetória setorial deliberadamente desigual — crescimento industrial concentrado no primeiro subperíodo e crescimento de serviços concentrado no segundo, um padrão plausível de transição estrutural. A Tabela 10 compara o efeito competitivo dinâmico (soma dos dois subperíodos, Equação 9) ao estático (Equação 1).

Tabela 10 — Efeito competitivo: decomposição dinâmica versus estática, totais regionais

Região	CE_r^{din} (soma de 2 subperíodos)	CE_r^{est}	Diferença
PI	23,55	25,65	−2,10
CE	25,08	25,93	−0,84
MA	−23,96	−24,97	1,01
BA	−4,96	−4,86	−0,09
PE	−19,71	−21,75	2,04

Fonte: elaboração própria, Equações 1 e 9, com trajetória hipotética de dois subperíodos.

A diferença entre as duas formas não é uniforme entre regiões — nem em magnitude, nem em sinal. Para Piauí e Ceará, a forma estática superestima o efeito competitivo em relação à forma dinâmica (diferenças negativas); para Maranhão e Pernambuco, ocorre o oposto: a forma estática *subestima* o desempenho competitivo real ao concentrar toda a comparação nos dois pontos extremos. Isso confirma, neste exemplo reduzido, a advertência de Barff e Knight (1988): a decomposição ponto a ponto pode inverter o sinal relativo da vantagem competitiva entre regiões dependendo de como a mudança estrutural se distribuiu dentro do intervalo, sobretudo quando o período é longo ou volátil.

9 FORMALIZAÇÃO INFERENCIAL: A ANOVA DE BERZEG (1978, 1984)

9.1 Justificativa

Como observam Selting e Loveridge (1992), por ser uma identidade determinística, nenhum componente da SSA clássica pode ser testado estatisticamente — não há erro-padrão, não há teste de hipótese, não há forma de dizer se um efeito competitivo de −4,29 (Bahia, Tabela 4) é "significativamente" diferente de zero ou apenas ruído amostral. Berzeg (1978, 1984) forneceu a fundamentação estatística definitiva ao recastar a identidade como um modelo linear de análise de variância (ANOVA), no qual o crescimento nacional é o intercepto, a composição setorial é um coeficiente estimado e o efeito competitivo é o **termo de erro** de uma regressão — passível, sob normalidade dos erros, de teste t.

9.2 Formalização

Considere a regressão da taxa de crescimento regional-setorial em variáveis binárias (*dummies*) de setor, sem intercepto separado (conjunto completo de *dummies*):

$$g_{ri} = \sum_{i=1}^{N} \beta_i D_i + u_{ri} \tag{10}$$

em que D_i é uma *dummy* igual a 1 se a observação pertence ao setor i e β_i, estimado por mínimos quadrados ordinários, é a média amostral de g_{ri} no setor i — o análogo, nesta formulação, do parâmetro de composição setorial g_{ni}. O resíduo $u_{ri} = g_{ri} - \hat{\beta}_i$ é a **taxa competitiva estimada**: sob a hipótese de erros normais e homocedásticos, a razão entre a média de u_{ri} em uma região e seu erro-padrão segue distribuição t de Student,

$$t_r = \frac{\bar{u}_r}{s/\sqrt{n_r}} \tag{11}$$

com s o desvio-padrão residual do modelo (Equação 10) e n_r o número de observações setoriais na região r — permitindo testar $H_0 : \bar{u}_r = 0$, isto é, se a região tem, em média, desempenho competitivo estatisticamente distinguível de zero.

9.3 Aplicação

A Tabela 11 mostra a decomposição célula a célula da Equação 10 aplicada ao painel de 15 observações (5 regiões × 3 setores) das Tabelas 1–2. A Tabela 12 aplica o teste da Equação 11 por região.

Tabela 11 — Regressão de Berzeg: taxa observada, componente de composição estimado e resíduo competitivo

Região	Setor	g_{ri}	$\hat{\beta}_i$ (mix estimado)	u_{ri} (competitivo)
PI	AGR	0,0500	0,0564	−0,0064
PI	IND	0,1444	0,1622	−0,0178
PI	SER	0,4000	0,3000	0,1000
CE	AGR	0,0533	0,0564	−0,0030
CE	IND	0,2682	0,1622	0,1060
CE	SER	0,3000	0,3000	0,0000
MA	AGR	0,0000	0,0564	−0,0564
MA	IND	0,1000	0,1622	−0,0622
MA	SER	0,2500	0,3000	−0,0500
BA	AGR	0,0500	0,0564	−0,0064
BA	IND	0,1484	0,1622	−0,0138
BA	SER	0,3000	0,3000	0,0000
PE	AGR	0,1286	0,0564	0,0722
PE	IND	0,1500	0,1622	−0,0122
PE	SER	0,2500	0,3000	−0,0500

Fonte: elaboração própria, Equação 10, mínimos quadrados ordinários com 15 observações.

Tabela 12 — Teste t do desempenho competitivo médio por região ($H_0 : \bar{u}_r = 0$; graus de liberdade = 12)

Região	$\bar{u}_r$	t_r	valor-p
PI	0,0253	0,7659	0,4585
CE	0,0343	1,0393	0,3192
MA	−0,0562	−1,7022	0,1145
BA	−0,0067	−0,2039	0,8418
PE	0,0033	0,1008	0,9213

Fonte: elaboração própria, Equação 11.

Nenhuma região atinge significância convencional de 5% neste exemplo — o mais próximo é o Maranhão, com $t = -1,70$ e valor-p=0,11, sugerindo desvantagem competitiva sistemática, mas não conclusiva na amostra. Esse resultado ilustra, mais do que qualquer conclusão substantiva sobre as regiões fictícias, a própria lição metodológica da Seção 9.1: a decomposição clássica (Tabela 4) mostraria o efeito competitivo do Maranhão como um número aparentemente grande e "real" (−23,25), mas a formalização de Berzeg revela que, com apenas três observações setoriais por região, esse número não é estatisticamente distinguível de zero ao nível de 5% — exatamente o tipo de afirmação que a SSA clássica é incapaz de fazer e que o limiar de significância listado no Quadro de Parâmetros Consolidados (Seção 13) torna operacional.

10 KNUDSEN (2000): AS DUAS FORMAS PROBABILÍSTICAS, ANOVA E TEORIA DA INFORMAÇÃO

10.1 Justificativa

Knudsen (2000) classifica os métodos de SSA em três famílias: os modelos contábeis tradicionais, os modelos de análise de variância (ANOVA) e os modelos de teoria da informação. As duas últimas são as "duas formas probabilísticas" que o artigo apresenta. A primeira é a ANOVA de Berzeg (1978, 1984), que o autor reescreve nas versões simples, com a extensão de Arcelus e dinâmica (equações 4 a 6 do artigo). A segunda é o *shift-share* de teoria da informação, derivado do princípio de mínima informação discriminante (MDI) (equações 7 a 19), ao qual o artigo acrescenta um modelo misto, com variável exógena contínua, para mostrar a flexibilidade da abordagem (equações 20 a 24). A ideia de fundo é ler o problema da SSA como a partição da variação de uma tabela de contingência com três dimensões (setor, região e ano). Assim lida, a SSA é um caso particular da classe de modelos para dados tabulares agregados usada em planejamento, geografia e ciência regional, e passa a admitir testes de hipótese sobre a variação do emprego por região ou setor.

A "extensão de Arcelus" a que Knudsen se refere, aqui e em todo o artigo, é a identidade de quatro termos da equação 2 — deslocamento regional e deslocamento diferencial —, formalizada na Seção 7.4 desta nota, e não a decomposição homotética da Seção 7.2, que o artigo não utiliza. A distinção importa porque as duas levam a objetos diferentes: o que a extensão acrescenta às formas probabilísticas é um efeito principal de região (G_r na ANOVA, D_r na forma informacional), que é a contraparte estatística do deslocamento regional r_{ri} — não do efeito competitivo homotético CE_r^* da Seção 6.

O artigo também qualifica a equivalência entre a identidade contábil (Equação 1) e a forma ANOVA (Equação 10). As duas são matematicamente equivalentes, mas a regressão estimada não reproduz os componentes contábeis, por duas razões: ela é medida em taxas, e não em empregos, de modo que os termos diferem pelo fator $E_{0,ri}$; e seus erros são heterocedásticos. Segundo Knudsen (2000), Berzeg (1978, 1984) mostra que as estimativas coincidem quando se supõe $E[e_{ri}^2] = \sigma^2 / w_{ri}$, com $w_{ri} = E_{0,ri} / \sum_{r,i} E_{0,ri}$, e se estima por mínimos quadrados ponderados. A regressão da Seção 9, estimada por mínimos quadrados ordinários sem ponderação, não tem essa propriedade: nela, a taxa g_{ri} de uma célula de emprego-base pequeno, cuja variância tende a ser maior, pesa tanto quanto a de uma célula grande.

Na comparação empírica do artigo (emprego do Bureau of Labor Statistics agregado nas divisões setoriais do BLS e nas nove divisões censitárias dos Estados Unidos, anos de 1970 e 1980), a forma informacional teve ajuste superior e discriminou melhor os parâmetros nos modelos simples e com a extensão de Arcelus: a porcentagem da *deviance* do modelo nulo explicada (PNMD, uma medida do tipo R^2) foi de 0,5163 e 0,6601,

contra R^2 de 0,1836 e 0,2284 da ANOVA correspondente. Na forma dinâmica, o ajuste foi fraco nos dois casos (0,0258 contra 0,0111). O autor conclui com cautela. Os modelos informacionais exigem pouca manipulação prévia dos dados, permitem incorporar a informação disponível sob a forma de restrições, colocam a SSA no campo da análise estatística de dados tabulares nominais e parecem úteis em dados com poucos valores extremos grandes; em contrapartida, seus parâmetros são mais difíceis de interpretar e nem sempre ajustam melhor que a ANOVA.

10.2 Formalização

Forma I (ANOVA). É a regressão da Equação 10 (Seção 9.2). Knudsen (2000) a escreve com intercepto, $g_{ri} = a + B_i + e_{ri}$ (sua equação 4), em que a estima g_n, B_i estima $g_{ni} - g_n$ e o erro e_{ri} estima o termo competitivo $g_{ri} - g_{ni}$; a Equação 10 usa o conjunto completo de *dummies* de setor no lugar do intercepto, o que é apenas outra parametrização. A extensão de Arcelus acrescenta um efeito de região, $g_{ri} = a + B_i + G_r + e_{ri}$ (equação 5), com $G_r = g_r - g_n$ e $e_{ri} = (g_{ri} - g_r) - (g_{ni} - g_n)$ — isto é, exatamente o deslocamento regional e o deslocamento diferencial da Equação 6, agora em taxas e com o segundo deslocado para o termo de erro. A forma dinâmica acrescenta ainda um efeito de período V_k (equação 6). Sob normalidade dos erros, a razão entre cada parâmetro e seu erro-padrão segue a distribuição t de Student.

Forma II (teoria da informação). Sejam $q_{ri} = E_{0,ri} / \sum_{r,i} E_{0,ri}$ a distribuição *a priori* (participações no ano-base) e $p_{ri} = E_{1,ri} / \sum_{r,i} E_{1,ri}$ a distribuição *a posteriori* (participações no ano terminal). O ganho de informação de Kullback e Leibler (1951), equação 7 do artigo, mede a informação obtida ao observar P dado Q:

$$I(P : Q) = \sum_{r,i} p_{ri} \, \ln \frac{p_{ri}}{q_{ri}} \tag{12}$$

O modelo de mínima informação discriminante escolhe P minimizando $I(P : Q)$ sujeito a restrições lineares que representam o que se sabe sobre a distribuição final, além de $\sum_{r,i} p_{ri} = 1$ e $p_{ri} \geq 0$ (equação 8). O problema pode ser resolvido pelo dual, um programa geométrico sem restrições (equação 9), mas, com restrições de igualdade lineares, o método de Lagrange leva diretamente a um modelo log-linear em p_{ri} (equação 10), e as quantidades resultantes são estimadores assintóticos de máxima verossimilhança. Na forma básica, a restrição fixa os totais setoriais, $\sum_r p_{ri} = o_i$ (equação 11), e a solução é $p_{ri} = q_{ri} \exp(a + o_i + f_{ri})$ (equação 12 do artigo). Na extensão de Arcelus — a da Seção 7.4 —, acrescenta-se a restrição dos totais regionais, $\sum_i p_{ri} = d_r$ (equação 15), e a solução passa a ser $p_{ri} = q_{ri} \exp(a + o_i + d_r + f_{ri})$ (equação 16). Reescrita em níveis de emprego (equação 17) e linearizada, ela dá a **forma estática** (equação 18 do artigo):

$$\ln \frac{E_{1,ri}}{E_{0,ri}} = A + O_i + D_r + \ln F_{ri} \tag{13}$$

em que A é o intercepto (crescimento comum), O_i é o efeito do setor (análogo, em escala logarítmica, do componente de composição setorial), D_r é o efeito da região (análogo, em escala logarítmica, do efeito competitivo regional) e $\ln F_{ri}$ é o termo de erro. A **forma dinâmica** pode ser obtida de duas maneiras: aplicando a Equação 13 a períodos sucessivos e somando ou tirando a média dos resultados, como em Barff e Knight (1988), ou acrescentando à tabela uma dimensão de tempo, com um efeito T_k para cada par de anos adjacentes $k = 1, \ldots, T$ (equação 19 do artigo):

$$\ln \frac{E_{k,ri}}{E_{k-1,ri}} = A + O_i + D_r + T_k + \ln F_{rik} \tag{14}$$

Nas duas formas, os parâmetros só são determinados a menos de uma constante aditiva: um nível de cada dimensão não pode ser estimado (o artigo os chama de *aliased*) e os demais são lidos em relação a ele.

Estimação. Como as soluções MDI são estimadores de máxima verossimilhança, Knudsen (2000) calibra esses modelos com métodos de modelos lineares generalizados (GLM), remetendo à literatura de regressão de

Poisson para dados de contagem agregados (FLOWERDEW; LOVETT, 1989; LOVETT; FLOWERDEW, 1989; MCCULLAGH; NELDER, 1983) e à inclusão de informação *a priori* por meio de *offsets* (KNUDSEN, 1992). Na forma estática usada nesta nota e na implementação de referência, o modelo estimado é um GLM de Poisson com ligação log, em que $\ln E_{0,ri}$ entra como *offset* (regressor com coeficiente fixado em 1):

$$E_{1,ri} \sim \text{Poisson}(\mu_{ri}), \qquad \ln \mu_{ri} = \ln E_{0,ri} + A + O_i + D_r \tag{15}$$

Os parâmetros são assintoticamente normais, de modo que a razão entre o coeficiente e seu erro-padrão dá o teste de Wald, $z_r = \hat{D}_r/\text{ep}(\hat{D}_r)$, sob $H_0 : D_r = 0$. O ajuste é medido pela *deviance*, assintoticamente distribuída como qui-quadrado, e resumido pela PNMD, $1-\mathcal{D}_{\text{modelo}}/\mathcal{D}_{\text{nulo}}$, que se lê como um R^2. Knudsen (2000) observa ainda que a ANOVA simples (sua equação 4) e a forma informacional simples (equação 14 do artigo, sem o efeito de região) deveriam produzir resultados idênticos se esta fosse calibrada com pesos w_{ri}^{-1} e erros $\ln F_{ri}$ normais (BERZEG, 1984; KNUDSEN; BARFF, 1991), e que os parâmetros das duas formas deveriam guardar uma relação exponencial. No texto do artigo essa relação aparece impressa como $B_i = \exp(O_i - 1)$; a leitura coerente com $g_{ri} = E_{1,ri}/E_{0,ri} - 1$ é $B_i = e^{O_i} - 1$. Na comparação empírica, porém, o autor não encontra uma relação precisa entre os parâmetros e atribui a discrepância à inversa generalizada usada para contornar a singularidade de $X^\top X$ na calibração.

Adaptações da implementação de referência. A implementação do projeto (`ssa_models.knudsen_mdi` e seção 9 do caderno `evolucao_shift_share.ipynb`) segue as Equações 13 a 15 e acrescenta três elementos que não estão no artigo. Primeiro, os erros-padrão são, por padrão, quase-Poisson: a matriz de covariância de máxima verossimilhança é multiplicada pela dispersão estimada $\hat{\phi} = \chi^2_{\text{Pearson}}/(n-p)$. Emprego não é uma contagem de Poisson, e os erros de máxima verossimilhança pura, que supõem variância igual à média, dependem da unidade de medida: a mesma série medida em empregos ou em milhares de empregos leva a conclusões de significância diferentes. Os erros quase-Poisson não têm esse problema e deixam as estimativas pontuais inalteradas; os erros de máxima verossimilhança pura do artigo continuam disponíveis como opção. Segundo, os efeitos regionais são recentrados para média ponderada nula, $\tilde{D}_r = D_r - \sum_s \omega_s D_s$, com $\omega_s = W_s/\sum_{s'} W_{s'}$ e W_r o emprego-base da região somado nos períodos usados (um na forma estática, T na dinâmica); o erro-padrão de $\tilde{D}_r$ é calculado para esse contraste a partir da matriz de covariância completa. Terceiro, o efeito regional é convertido em taxa competitiva por período, $e^{\tilde{D}_r} - 1$, e em empregos, $CE_r = (e^{\tilde{D}_r} - 1)\, W_r$, na mesma escala dos componentes das Seções 4 a 8. Quando $\hat{\phi}$ fica muito acima de 1, a correção quase-Poisson amplia os erros-padrão pelo fator $\hat{\phi}^{1/2}$; o modelo binomial negativo (FLOWERDEW; LOVETT, 1989) é a alternativa que modela a sobredispersão de forma explícita.

Modelo misto. Para ilustrar a flexibilidade da Forma II, Knudsen (2000) trata o caso em que interessa uma sub-região (seu exemplo é um condado de Maryland avaliado frente à economia dos Estados Unidos). Nos modelos tabulares, a significância dos parâmetros depende da variação em torno da média da própria tabela, o que obrigaria a incluir na análise todas as unidades da economia de referência. A solução proposta é tomar a informação nacional das margens da tabela maior e introduzi-la como variável contínua exógena: com N_i o emprego nacional no setor i, o modelo calibrado é $\ln(E_{1,ri}/E_{0,ri}) = \ln N_i + A + O_i + \ln F_{ri}$ (equação 23), e seu análogo ANOVA é $g_{ri} = a + n_i + B_i + e_{ri}$ (equação 24). Esse modelo não é implementado no projeto nem ilustrado nesta nota.

10.3 Aplicação

A Tabela 13 estima a forma estática (Equações 13 e 15) sobre o mesmo painel de 15 observações das Tabelas 1 e 2, com Bahia (a região "neutra" do exemplo) e Agropecuária como categorias de referência, isto é, como os níveis *aliased* de cada dimensão. Para manter a comparação com o artigo, os erros-padrão da tabela são os de máxima verossimilhança pura, com dispersão fixada em 1.

Tabela 13 — Forma informacional estática de Knudsen (Equações 13 e 15): coeficientes, erro-padrão e teste de Wald

Termo	Coeficiente ($\hat{D}_r$ ou $\hat{O}_i$)	Erro-padrão	z	valor-p
Intercepto (A, referência BA×AGR)	0,0490	0,040	1,22	0,222
Região: PI (rel. a BA)	0,0388	0,049	0,79	0,427
Região: CE (rel. a BA)	0,0277	0,042	0,66	0,507
Região: MA (rel. a BA)	−0,0426	0,053	−0,81	0,420
Região: PE (rel. a BA)	−0,0126	0,040	−0,31	0,754
Setor: IND (rel. a AGR)	0,1065	0,045	2,39	0,017
Setor: SER (rel. a AGR)	0,2048	0,038	5,32	0,000

Fonte: elaboração própria, Equações 13 e 15, GLM Poisson com *offset* $\ln E_{0,ri}$ e erros-padrão de máxima verossimilhança pura, 15 observações, 8 graus de liberdade residuais. *Deviance*/g.l. = 0,49; PNMD = 0,90.

A razão *deviance*/g.l. de 0,49, e a dispersão de Pearson de valor semelhante ($\hat{\phi} \approx 0{,}50$), não indicam sobredispersão neste painel. Com os erros quase-Poisson que a implementação usa por padrão, os erros-padrão da Tabela 13 seriam multiplicados por $\hat{\phi}^{1/2} \approx 0{,}70$, e nenhuma conclusão mudaria: os efeitos regionais continuam não significativos a 5%, e os dois efeitos setoriais continuam significativos.

O primeiro resultado notável não está nos efeitos de região, mas nos de setor. Na Seção 9, os coeficientes setoriais da Forma I foram usados apenas como médias amostrais, sem teste; a Forma II testa formalmente a composição setorial e a rejeita como nula com folga (Indústria: $p = 0,017$; Serviços: $p < 0,001$). O componente de composição setorial deste exemplo não é apenas numericamente grande: é estatisticamente bem determinado, ao contrário do componente competitivo, discutido a seguir. O padrão lembra o resultado empírico de Knudsen (2000), em que a forma informacional discriminou melhor os parâmetros setoriais do que a ANOVA.

Os efeitos de região reproduzem a conclusão substantiva da Seção 9: nenhuma região diverge de forma estatisticamente significativa da região de referência ao nível de 5%, e o Maranhão tem o coeficiente mais negativo do conjunto ($-0,0426$), embora com $p = 0,420$, distante do limiar. A recentragem ponderada da implementação (Seção 10.2) mudaria o nível desses efeitos, porque subtrai a mesma constante de todos os $\hat{D}_r$, mas não as diferenças entre regiões nem sua ordenação. A Tabela 14 compara diretamente as duas formas.

Tabela 14 — Comparação Forma I (ANOVA) versus Forma II (teoria da informação): efeito regional e significância

Região	Forma I: $\bar{u}_r$ (Tabela 12)	Forma I: valor-p	Forma II: $\hat{D}_r$ (rel. a BA)	Forma II: valor-p
PI	0,0253	0,459	0,0388	0,427
CE	0,0343	0,319	0,0277	0,507
MA	−0,0562	0,115	−0,0426	0,420
BA	−0,0067	0,842	(referência)	—
PE	0,0033	0,921	−0,0126	0,754

Fonte: elaboração própria, Tabela 12 e Tabela 13.

As duas formas não são diretamente comparáveis célula a célula. A Forma I deixa a região no termo de erro e reporta o desvio médio de cada região em relação às médias setoriais não ponderadas, em unidades de taxa; a Forma II reporta um coeficiente log-multiplicativo relativo à Bahia. A comparação que o próprio Knudsen (2000) faz entre parâmetros regionais usa a ANOVA com efeito de região explícito (sua equação 5) frente à equação 18. Ainda assim, as duas formas concordam no essencial: Piauí e Ceará ficam acima da Bahia, o Maranhão é sempre o mais negativo, e nenhuma região é estatisticamente distinguível de zero, ou da referência, a 5%. Elas divergem nas posições intermediárias: o Ceará supera o Piauí na Forma I e fica atrás dele na Forma II, e Pernambuco fica acima da Bahia na Forma I e abaixo dela na Forma II.

Essa concordância parcial não deve ser generalizada. Na Poisson, a variância cresce com a média, de modo que as células com mais emprego pesam mais sem que seja preciso escolher pesos, ponderação que na Forma I precisa ser imposta por mínimos quadrados ponderados. Por isso, as duas formas tendem a divergir mais em painéis com heterogeneidade de escala pronunciada entre células região-setor (células de emprego-base muito pequeno ao lado de células muito grandes), situação em que a Forma I sem ponderação pode subestimar a incerteza nas células pequenas e superestimá-la nas grandes. Em painéis reais, a dispersão $\hat{\phi}$ deve ser verificada antes de reportar os testes da Forma II.

11 SHIFT-SHARE ESPACIAL: NAZARA-HEWINGS (2004)

11.1 Justificativa

Todas as reformulações anteriores tratam cada região como uma unidade isolada. Nazara e Hewings (2004) argumentaram que essa suposição é implausível quando regiões vizinhas compartilham mercados de trabalho, cadeias de fornecimento ou efeitos de transbordamento (*spillover*) — o desempenho competitivo de uma região pode estar sistematicamente correlacionado com o de suas vizinhas, positiva ou negativamente. A proposta foi incorporar uma matriz de pesos espaciais à decomposição, criando uma taxonomia de vinte estruturas de decomposição possíveis conforme o componente considerado "local" ou "vizinho".

11.2 Formalização

Seja w_{rs} o elemento da matriz de pesos espaciais W — aqui, contiguidade de fronteira terrestre entre as unidades federativas, padronizada em linha ($\sum_s w_{rs} = 1$ para toda região r com ao menos um vizinho). Define-se a **taxa competitiva** regional (para distinguir do efeito competitivo em nível, CE_r, que depende da escala de emprego da região):

$$c_r = \frac{CE_r}{E_{0,r\bullet}} \tag{16}$$

O componente espacial central da abordagem de Nazara-Hewings é a **defasagem espacial** da taxa competitiva — a média (ponderada pela contiguidade) da taxa competitiva das regiões vizinhas:

$$(Wc)_r = \sum_s w_{rs}\, c_s \tag{17}$$

A diferença $c_r - (Wc)_r$ indica se a região tem desempenho competitivo destoante de sua vizinhança imediata (positiva: melhor que os vizinhos; negativa: pior). Para testar se essa dependência espacial é sistemática — e não um artefato de amostra pequena —, calcula-se o **I de Moran global** sobre as taxas competitivas (nunca sobre o emprego em nível, cuja heterogeneidade de escala entre regiões mascara inteiramente o padrão espacial):

$$I = \frac{n}{S_0} \cdot \frac{z' W z}{z' z}, \qquad z_r = c_r - \bar{c}, \qquad S_0 = \sum_r \sum_s w_{rs} \tag{18}$$

com valor esperado sob a hipótese nula de aleatoriedade espacial $E[I] = -1/(n-1)$. Valores de I acima de $E[I]$ indicam autocorrelação espacial positiva (regiões vizinhas com taxas competitivas parecidas); valores abaixo indicam autocorrelação negativa (vizinhos dissimilares).

11.3 Aplicação

A malha de contiguidade das cinco regiões deste exemplo segue as fronteiras terrestres reais entre as unidades federativas: Piauí faz fronteira com as quatro demais (Ceará, Maranhão, Bahia e Pernambuco), Ceará e Pernambuco fazem fronteira entre si, e Bahia e Pernambuco também. Maranhão e Bahia, apesar de ambos vizinhos do Piauí, não fazem fronteira uma com a outra. A Tabela 15 apresenta a matriz padronizada em linha.

Tabela 15 — Matriz de pesos espaciais W (contiguidade de fronteira, padronizada em linha)

	PI	CE	MA	BA	PE
PI	0,000	0,250	0,250	0,250	0,250
CE	0,500	0,000	0,000	0,000	0,500
MA	1,000	0,000	0,000	0,000	0,000
BA	0,500	0,000	0,000	0,000	0,500
PE	0,333	0,333	0,000	0,333	0,000

Fonte: elaboração própria a partir de fronteiras terrestres reais entre as cinco unidades federativas (subconjunto ilustrativo; ver Seção 14).

Tabela 16 — Taxa competitiva local, defasagem espacial e hiato (Equações 16–17)

Região	c_r (taxa competitiva local)	$(Wc)_r$ (média dos vizinhos)	Hiato $c_r - (Wc)_r$
PI	4,33%	−1,12%	5,45 p.p.
CE	3,01%	1,20%	1,81 p.p.
MA	−5,17%	4,33%	−9,50 p.p.
BA	−0,38%	1,20%	−1,58 p.p.
PE	−1,93%	2,32%	−4,25 p.p.

Fonte: elaboração própria, Equações 16 e 17.

O caso do Maranhão é o mais informativo: sua taxa competitiva local é a mais negativa do conjunto (−5,17%), mas seu único vizinho na malha, o Piauí, tem a taxa mais positiva (4,33%) — um hiato de −9,5 pontos percentuais em relação à própria vizinhança. Isso é o oposto do padrão que a hipótese de *spillover* positivo prediria (vizinhos com desempenho parecido) e resulta, para este pequeno conjunto de cinco regiões, em um I de Moran global de $I = -0{,}4852$, abaixo do valor esperado sob aleatoriedade $E[I] = -0{,}25$ — um sinal de dissimilaridade, e não de agrupamento espacial positivo, entre vizinhos. Como discutido na Seção 14, um I de Moran com apenas cinco unidades tem poder estatístico praticamente nulo; o valor é reportado aqui unicamente para ilustrar o cálculo da Equação 18, não como evidência substantiva de dependência espacial.

12 SÍNTESE: A LÓGICA DA EVOLUÇÃO METODOLÓGICA

O Quadro 1 resume, para cada variante tratada, qual falha da variante anterior ela ataca e o que permanece em aberto depois dela — a mesma lógica de "problema → correção → novo limite" que estruturou as Seções 4 a 11.

Quadro 1 — Evolução dos componentes da SSA: problema atacado e limite remanescente

Variante	Problema que ataca	Mudança estrutural	Limite remanescente
Dunn (1960) — clássico	(linha de base)	Identidade aditiva de 3 componentes	Efeito competitivo contaminado por estrutura; sem inferência
Fuchs (1959) / pesos terminais	Viés do ano de ponderação	Média ou reversão de pesos	Sensibilidade permanece no efeito de alocação (Seção 6)
Esteban-Marquillas (1972)	Contaminação estrutural do efeito competitivo	Emprego homotético; efeito de alocação	Sinal de AE sensível à escolha de pesos (Herzog-Olsen, 1977)
Arcelus (1984), Modelo I	Homotetização restrita ao efeito competitivo	Extensão da partição homotética a todos os componentes	Dois dos quatro novos subcomponentes são nulos por construção ao nível regional (Seção 7.3)
Arcelus (1984), Modelo II	Competitivo de Dunn não distingue desempenho da região do desempenho do setor	Partição de CE_r em deslocamento regional e diferencial, com g_r como referência	Somado por região, o diferencial é $-IM_r$ por construção (Seção 7.4); base das formas probabilísticas de Knudsen (2000)
Barff-Knight (1988)	Viés de ponto-a-ponto e crescimento composto	Soma de decomposições anuais/subperiódicas	Ainda determinístico; exige dados de alta frequência
Berzeg (1978, 1984)	Impossibilidade de teste estatístico	Identidade recastada como ANOVA/regressão	Pressupõe normalidade; erro absorve toda variação não sistemática
Knudsen (2000)	ANOVA heterocedástica, que depende de pesos impostos para reproduzir a identidade	*Shift-share* de mínima informação discriminante: modelo log-linear estimado por máxima verossimilhança (GLM de Poisson com *offset* pelo emprego-base)	Parâmetros em escala log, de interpretação mais difícil; erros de máxima verossimilhança pura exigem correção de dispersão (quase-Poisson)
Nazara-Hewings (2004)	Regiões tratadas como independentes	Matriz de pesos espaciais; defasagem espacial	Sensível à especificação da matriz; exige N grande para inferência confiável

Fonte: elaboração própria, síntese das Seções 4 a 11.

13 QUADRO DE PARÂMETROS CONSOLIDADOS

Parâmetro	Valor adotado
Número de regiões no exemplo (R)	5 (PI, CE, MA, BA, PE)
Número de setores no exemplo (N)	3 (Agropecuária, Indústria, Serviços)
Natureza dos dados de emprego	Sintéticos/hipotéticos, não correspondem a estatísticas oficiais
Ano-base / ano-terminal	t_0 / t_1 genéricos (rótulos hipotéticos, sem correspondência calendárica)

Parâmetro	Valor adotado
Número de subperíodos na decomposição dinâmica (Seção 8)	2, com trajetória setorial hipotética e deliberadamente desigual entre subperíodos
Especificação da regressão de Berzeg (Seção 9)	Mínimos quadrados ordinários, conjunto completo de *dummies* de setor, sem ponderação por emprego
Nível de significância de referência (Seção 9)	5%
Graus de liberdade da regressão de Berzeg	$n - k = 15 - 3 = 12$
Especificação do modelo de Knudsen (Seção 10)	Forma estática (equação 18 de Knudsen, 2000): GLM Poisson, ligação log, *offset* $\ln E_{0,ri}$, categorias de referência BA (região) e AGR (setor)
Erros-padrão do modelo de Knudsen (Seção 10)	Máxima verossimilhança pura na Tabela 13; quase-Poisson ($\hat{\phi}$ = qui-quadrado de Pearson/g.l.) por padrão na implementação
Diagnóstico de dispersão (Seção 10)	$\hat{\phi} \gg 1$ indica sobredispersão; modelo binomial negativo como alternativa
Critério de vizinhança espacial (Seção 11)	Contiguidade de fronteira terrestre real entre as 5 unidades federativas, padronizada em linha
Base de cálculo do I de Moran (Seção 11)	Taxa competitiva $c_r = CE_r/E_{0,r\bullet}$, nunca o emprego em nível

14 LIMITAÇÕES

Escala do exemplo numérico. Cinco regiões e três setores foram escolhidos exclusivamente por clareza expositiva — o quadro é pequeno demais para qualquer inferência estatística com poder adequado. Os testes t e de Wald das Seções 9 e 10, e o I de Moran da Seção 11, devem ser lidos como demonstrações do cálculo, não como evidência substantiva; com $n = 5$, o I de Moran em particular tem variância amostral elevada e não deve ser interpretado como teste confiável de dependência espacial.

Dados inteiramente sintéticos. Nenhum valor de emprego neste documento corresponde a estatística oficial de Piauí, Ceará, Maranhão, Bahia ou Pernambuco — os nomes das unidades federativas foram usados apenas para ancorar a matriz de contiguidade espacial (Seção 11) em fronteiras reais, não para descrever essas economias.

Trajetória do exemplo dinâmico é arbitrária. A divisão em dois subperíodos e a distribuição de crescimento setorial entre eles (Seção 8) foram escolhidas para exibir divergência entre a forma dinâmica e a estática, não estimadas a partir de nenhum processo real; a magnitude da divergência em uma aplicação empírica dependerá inteiramente da volatilidade e do comprimento do período analisado, como já advertiam Barff e Knight (1988).

Arcelus II formalizado por fonte secundária. A Seção 7.4 formaliza o segundo modelo de Arcelus (1984) a partir das equações 2, 2a, 2b e 2c de Knudsen (2000, p. 179), que as apresenta como "a extensão de Arcelus" e as credita ao original. A álgebra foi verificada aqui — a identidade fecha à precisão de máquina e as três propriedades da Equação 8 valem —, mas o artigo de Arcelus (1984), *Growth and Change* 15(1), pp. 3–8, não foi consultado diretamente. Duas ressalvas, detalhadas ao fim da Seção 7.4: os ponderadores impressos em Knudsen (2000) são os do ano terminal, com os quais a identidade não fecha, e esta nota adota os do ano-base; e a correspondência entre os nomes de Arcelus (efeitos de crescimento e de composição regionais) e os termos r_{ri} e d_{ri} é leitura da álgebra, não verificada contra a nomenclatura do original. O modelo está implementado em `ssa_models.arcelus_ii` e entra na comparação de recuperação do caderno.

Adaptações ao modelo de Knudsen (2000). A Seção 10 foi conferida com o texto integral do artigo, e as equações que ela cita (4 a 6, 7 a 19 e 20 a 24) seguem a numeração do original. Três elementos não vêm do artigo, mas da implementação de referência do projeto: os erros-padrão quase-Poisson usados por padrão, a recentragem de D_r para média ponderada nula e a conversão $(e^{D_r} - 1)\, W_r$ em empregos. O artigo também não discute sobredispersão; a menção ao modelo binomial negativo vem de Flowerdew e Lovett (1989). A relação entre os parâmetros das Formas I e II segue a leitura $B_i = e^{O_i} - 1$, que difere da forma impressa no

artigo, e o próprio autor não a encontrou com precisão nos dados (Seção 10.2). Por fim, o modelo misto com variável exógena contínua (equações 20 a 24) é apenas descrito, sem implementação nem exemplo numérico, e a forma dinâmica (equação 19) é formalizada mas não aplicada ao exemplo, cujas trajetórias de subperíodo da Seção 8 são hipotéticas.

Matriz de contiguidade reduzida. A malha espacial da Seção 11 usa apenas cinco das 26 unidades federativas mais o Distrito Federal — um subconjunto ilustrativo, não a matriz de contiguidade completa da federação brasileira (que integra o código computacional do projeto mais amplo do qual esta nota deriva). Padrões de dependência espacial identificados em um subconjunto de cinco regiões não são generalizáveis à matriz completa.

Sensibilidade a escolha não neutra de pesos. Como demonstrado na Seção 5 e na Seção 6.3, tanto o efeito competitivo clássico quanto — de forma mais acentuada, e inclusive com inversão de sinal — o efeito de alocação de Esteban-Marquillas são sensíveis à escolha do ano de ponderação. Essa sensibilidade é uma propriedade do método, não um artefato deste exemplo específico, e já havia sido documentada empiricamente por Herzog e Olsen (1977) em dados reais das regiões do U.S. Bureau of Economic Analysis.

REFERÊNCIAS

ARCELUS, Francisco J. An extension of shift-share analysis. **Growth and Change**, v. 15, n. 1, p. 3-8, 1984.

BARFF, Richard A.; KNIGHT, Prentice L. Dynamic shift-share analysis. **Growth and Change**, v. 19, n. 2, p. 1-10, 1988.

BERZEG, Korkut. The empirical content of shift-share analysis. **Journal of Regional Science**, v. 18, n. 3, p. 463-469, 1978.

BERZEG, Korkut. A note on statistical approaches to shift-share analysis. **Journal of Regional Science**, v. 24, n. 2, p. 277-285, 1984.

DUNN, Edgar S. A statistical and analytical technique for regional analysis. **Papers of the Regional Science Association**, v. 6, p. 97-112, 1960.

ESTEBAN-MARQUILLAS, Joan M. A reinterpretation of shift-share analysis. **Regional and Urban Economics**, v. 2, n. 3, p. 249-255, 1972.

FLOWERDEW, Robin; LOVETT, Andrew. Compound and generalized Poisson models for interurban migration. In: CONGDON, Peter; BATEY, Peter (org.). **Advances in Regional Demography**. London: Belhaven Press, 1989. p. 246-256.

FUCHS, Victor R. Changes in the location of US manufacturing since 1929. **Journal of Regional Science**, v. 1, n. 2, p. 1-17, 1959.

HAYNES, Kingsley E.; MACHUNDA, Z. B. Considerations in extending shift-share analysis: note. **Growth and Change**, v. 18, n. 2, p. 69-78, 1987.

HERZOG, Henry W.; OLSEN, Richard J. Shift-share analysis revisited: the allocation effect and the stability of regional structure. **Journal of Regional Science**, v. 17, n. 3, p. 441-454, 1977.

HOUSTON, David B. The shift and share analysis of regional growth: a critique. **Southern Economic Journal**, v. 33, p. 577-581, 1967.

KEIL, Stanley R. On the value of homotheticity in the shift-share framework. **Growth and Change**, v. 23, n. 4, p. 469-493, 1992.

KNUDSEN, Daniel C. Generalizing Poisson regression: including a priori information using the method of offsets. **The Professional Geographer**, v. 44, p. 202-208, 1992.

KNUDSEN, Daniel C. Shift-share analysis: further examination of models for the description of economic change. **Socio-Economic Planning Sciences**, v. 34, n. 3, p. 177-198, 2000.

KNUDSEN, Daniel C.; BARFF, Richard. Shift-share analysis as a linear model. **Environment and Planning A**, v. 23, n. 3, p. 421-431, 1991.

KULLBACK, Solomon; LEIBLER, Richard A. On information and sufficiency. **The Annals of Mathematical Statistics**, v. 22, n. 1, p. 79-86, 1951.

LOVETT, Andrew; FLOWERDEW, Robin. Analysis of count data using Poisson regression. **Professional Geographer**, v. 41, n. 2, p. 190-198, 1989.

LOVERIDGE, Scott; SELTING, Anne C. A review and comparison of shift-share identities. **International Regional Science Review**, v. 21, n. 1, p. 37-58, 1998.

MCCULLAGH, Peter; NELDER, John A. **Generalized linear models**. London: Chapman and Hall, 1983.

NAZARA, Suahasil; HEWINGS, Geoffrey J. D. Spatial structure and taxonomy of decomposition in shift-share analysis. **Growth and Change**, v. 35, n. 4, p. 476-490, 2004.

PERLOFF, Harvey S.; DUNN, Edgar S.; LAMPARD, Eric E.; MUTH, Richard F. **Regions, resources, and economic growth**. Baltimore: Johns Hopkins University Press, 1960.

ROSENFELD, Stephen S. *(referência a ser completada conforme a fonte primária).*

SELTING, Anne C.; LOVERIDGE, Scott. **A summary of the literature on shift-share analysis**. Regional Research Institute, West Virginia University, 1992.

Nota de transparência: este documento formaliza os dois modelos de Arcelus (1984) — o Modelo I, homotético (Equação 5, Seção 7.2), e o Modelo II, de deslocamento regional (Equação 6, Seção 7.4) —, mas o Modelo II foi reconstruído a partir de Knudsen (2000, equações 2 a 2c), fonte secundária, sem consulta ao artigo original de Arcelus; a álgebra foi verificada, a nomenclatura não. A Seção 10 foi revisada com base no texto integral de Knudsen (2000): as equações do artigo são citadas pela numeração original, e as adaptações da implementação de referência (erros quase-Poisson, recentragem ponderada de D_r e conversão em empregos) estão identificadas como tais na Seção 10.2 e na Seção 14. A referência a Rosenfeld (1959), citada na literatura secundária como um dos primeiros a apontar o defeito do efeito competitivo clássico, não pôde ser completada com periódico, volume e página exatos e é sinalizada como incompleta na lista de referências, em vez de inventada. Todos os valores numéricos das Tabelas 1 a 16 são sintéticos e devem ser validados como tal antes de qualquer circulação do documento; as medidas de ajuste citadas na Seção 10.1 são as reportadas por Knudsen (2000) para dados reais dos Estados Unidos.